Ensamblaje y Anotación de Genomas Bacterianos

Héctor Fabio Espitia-Navarro

12 de marzo de 2023

Tabla de contenidos

Bienvenid@

Esta es una guía de Bioinformática para ensamblar y anotar genomas bacterianos a partir de muestras de aislamientos secuenciados con tecnologías de secuenciación de segunda generación (*Next Generation Sequencing, NGS*).

Convenciones

El código fuente, nombres de archivos, y los comandos y su salida, están formateados en fuente monoespaciada. Por ejemplo, `ls`, `/ruta/al/archivo.txt` o el siguiente comando y su salida:

```
ls -l /home
```

```
total 4
drwxr-xr-x 40 hector hector 4096 mar 12 16:52 hector
```

Las palabras en idiomas diferentes al español aparecen en cursiva, p. ej. *kernel*, o *dash*.

Bloques especiales

Textos con información de especial atención se presentan en bloques (recuadros) especiales que se diferencian por su color. Existen cinco tipos de bloques especiales:

> **Nota**
>
> Este es un ejemplo de una nota.

> **Importante**
>
> Este es un texto que corresponde a una información importante.

> **Tip**
>
> Así se ven los consejos o trucos

> **Precaución**
>
> Este bloque denota una información de precaución

> **Advertencia**
>
> Este bloque denota una información de advertencia.

1 Preparación del entorno de trabajo

1.1 Estructura de directorios

Para que cada proyecto esté organizado en carpetas independientes, primero crearemos el directorio para los proyectos. Abra una terminal y ejecute las siguientes órdenes:

```
cd $HOME
mkdir proyectos
```

> **!** Importante
>
> A partir de aquí, se asume que usted debe ejecutar todos los comandos mostrados en la terminal.

Ahora, se creará la estructura para nuestro proyecto de ensamblaje dentro del directorio `proyectos`. En la estructura se contemplan subdirectorios de datos, calidad y resultados:

```
mkdir -p proyectos/ensamblaje/{datos,resultados,scripts}
mkdir -p proyectos/ensamblaje/datos/qc/fastqc
mkdir -p proyectos/ensamblaje/resultados/{00_datos_limpios,01_ensamblaje,02
    _ensamblaje_qc,03_anotacion}
mkdir -p proyectos/ensamblaje/resultados/00_datos_limpios/qc/{fastp,fastqc}
```

La estructura final del directorio del directorio del proyecto se puede ver con el comando `tree`:

```
tree -L 4 --charset HTML proyectos/ensamblaje
```

```
proyectos/ensamblaje
|-- datos
|   `-- qc
|       `-- fastqc
|-- resultados
|   |-- 00_datos_limpios
|   |   `-- qc
|   |       |-- fastp
```

```
|   |       `-- fastqc
|   |-- 01_ensamblaje
|   |-- 02_ensamblaje_qc
|   `-- 03_anotacion
`-- scripts

12 directories, 0 files
```

1.2 Ambiente Conda e instalación de programas

Una manera eficiente y rápida para instalar todos los programas necesarios para el ensamblaje y anotación de los genomas, consiste en usar Conda[1], un software de libre distribución para administrar ambientes de software e instalación de programas.

1.2.1 Instalación Conda: mambaforge

Instalaremos una implementación liviana de Conda de la comunidad conda-forge[2] llamada miniforge[3], que además viene con el gestor de paquetes `mamba`, el cual es más rápido y eficiente que `conda`.

Primero, descarguemos el instalador:

```
wget https://github.com/conda-forge/miniforge/releases/latest/download/Mambaforge-
    Linux-x86_64.sh
```

> **Nota**
>
> Toda la información acerca de miniforge y otros instaladores están disponibles en https://github.com/conda-forge/miniforge

Ahora iniciemos el instalador:

```
# Adicionar permiso de ejecución
chmod +x Mambaforge-Linux-x86_64.sh

# Ejecutar el instalador
./Mambaforge-Linux-x86_64.sh
```

[1] Documentación de Conda (en inglés): https://docs.conda.io/en/latest/
[2] Conda-forge: https://conda-forge.org/
[3] Miniforge en GitHub: https://github.com/conda-forge/miniforge.

Al ejecutar el anterior comando, verá un mensaje de los términos de la licencia como este:

```
Welcome to Mambaforge 22.11.1-4

In order to continue the installation process, please review the license
agreement.
Please, press ENTER to continue
>>>
```

Presione la tecla `<ENTER>` varias veces hasta que el instalador solicite aceptar los términos de la licencia:

```
Do you accept the license terms? [yes|no]
[no] >>>
```

Responda `yes`

A continuación el instalador solicitará el lugar donde instalará Mambaforge. Puede confirmar la ubicación por defecto (en su directorio *home*: `~/mambaforge`) presionando `<ENTER>`:

```
Mambaforge will now be installed into this location:
/home/hector/mambaforge

  - Press ENTER to confirm the location
  - Press CTRL-C to abort the installation
  - Or specify a different location below

[/home/hector/mambaforge] >>>
```

Una vez el instalador finaliza la copia de archivos, le preguntará si desea inicializar Mabaforge:

```
...
Transaction finished
installation finished.
Do you wish the installer to initialize Mambaforge
by running conda init? [yes|no]
[no] >>>
```

Responda `yes`. Después, verá un mensaje que indica los cambios realizados en los archivos de configuración para inicializar Mambaforge:

```
...
no change     /home/hector/mambaforge/bin/conda
no change     /home/hector/mambaforge/bin/conda-env
```

```
no change     /home/hector/mambaforge/bin/activate
no change     /home/hector/mambaforge/bin/deactivate
no change     /home/hector/mambaforge/etc/profile.d/conda.sh
no change     /home/hector/mambaforge/etc/fish/conf.d/conda.fish
no change     /home/hector/mambaforge/shell/condabin/Conda.psm1
no change     /home/hector/mambaforge/shell/condabin/conda-hook.ps1
no change     /home/hector/mambaforge/lib/python3.10/site-packages/xontrib/conda.
    xsh
no change     /home/hector/mambaforge/etc/profile.d/conda.csh
modified      /home/hector/.bashrc

==> For changes to take effect, close and re-open your current shell. <==

Added mamba to /home/hector/.bashrc

==> For changes to take effect, close and re-open your current shell. <==
```

Para que la instalación tome efecto, cierre y abra nuevamente la terminal.

Seguramente cuando abra nuevamente la terminal, notará que el *prompt* luce diferente; algo parecido a esto:

```
(base) hector@Ubuntu:~$
```

Esto es debido a que Conda usa el *prompt* como medio para informar el ambiente se encuentra activo (en uso) actualmente, mostrándolo entre paréntesis al inicio del prompt. En el ejemplo anterior aparece la palabra `base`; este es el nombre del ambiente "base" por defecto de Conda.

1.2.2 Creación del ambiente Conda

El siguiente paso es crear un ambiente Conda en donde se instalarán todas los programas requeridos. Un ambiente es un directorio que contiene una colección especifica de paquetes (programas) de Conda (con una versión específica) que se han instalado.

Para crear el ambiente, ejecute las siguientes órdenes:

```
mamba create -n ensam
```

```
...
Looking for: []

Preparing transaction: done
```

```
Verifying transaction: done
Executing transaction: done

To activate this environment, use

     $ mamba activate ensam

To deactivate an active environment, use

     $ mamba deactivate
```

Como pudo ver, `mamba` despliega un mensaje de confirmación de creación del ambiente.

> **!** Importante
>
> Para poder usar el ambiente creado, siempre se debe activarlo primero:
>
> ```
> mamba activate <ambiente>
> ```
>
> donde `<ambiente>` es el nombre del ambiente creado.
> Cuando ya no se necesita el ambiente, se debe desactivar:
>
> ```
> mamba deactivate
> ```

1.2.3 Instalación de paquetes

Ahora instalaremos los paquetes requeridos. Primero active el ambiente:

```
mamba activate ensam
```

> **i** Nota
>
> Cuando se activa correctamente, podrá ver el nombre del ambiente recién activado en el *prompt*, en este caso `ensam` en lugar de `base`:
>
> ```
> (ensam) hector@Ubuntu:~$
> ```

Ahora instale los paquetes ejecutando el siguiente comando:

```
mamba install -c bioconda csvtk fastp fastqc java-jdk multiqc ncbi-datasets-cli \
  pigz prokka quast spades sra-tools wget
```

A continuación verá algunos mensajes y barras de progreso mientras mamba descarga los listados de paquetes y busca los paquetes que se ordenaron instalar. Al final mamba solicitará que confirme la instalación de los paquetes:

```
...
  Summary:

  Install: 290 packages

  Total download: 1GB──────────────────────────────────────────────────────────────




Confirm changes: [Y/n]
```

Confirme escribiendo `Y` y después presione `<ENTER>`. De nuevo verá una serie de tareas completadas y barras de progreso mientras la instalación transcurre.

Aunque se ordenó instalar 11 paquetes, cada uno de ellos requiere múltiples dependencias, es decir, paquetes adicionales para funcionar. Aquí es donde se facilitan las cosas: mamba (o conda) se encarga de revisar las dependencias de cada paquete, instalarlas y configurarlas automáticamente para que cada programa funcione adecuadamente.

Al finalizar la instalación verá un mensaje parecido a este:

```
...
Downloading and Extracting Packages

Preparing transaction: done
Verifying transaction: done
Executing transaction: \ The default QUAST package does not include:
* GRIDSS (needed for structural variants detection)
* SILVA 16S rRNA database (needed for reference genome detection in metagenomic
    datasets)
* BUSCO tools and databases (needed for searching BUSCO genes) -- works in Linux
    only!

To be able to use those, please run
    quast-download-gridss
    quast-download-silva
    quast-download-busco

done
```

Ahora todo el software requerido para el análisis de los datos está instalado.

2 Obtención de datos

2.1 Software requerido

Software	Versión	Descripción	Ref.
SRA Tools	3.0.3	Colección de herramientas para descargar datos desde la base de datos SRA[1] (del inglés *Sequence Read Archive;* Katz et al. (2022)) del NCBI (del inglés *National Center for Biotechnology Information*)	Repositorio GitHub

2.2 Datos

Descargaremos cuatro muestras de secuenciación de genoma completo o WGS (del inglés *Whole Genome Sequencing*) del organismo *Helicobacter pylori*, para ser ensambladas. Para descargar estas muestras necesitaremos los identificadores (número de acceso o *accession number* en inglés) en la base de datos SRA:

1. SRR22388518
2. SRR22388519
3. SRR18335437
4. SRR18335438

[1] Sequence Read Archive

2.3 Descarga

> **Importante**
>
> Recuerde siempre activar el ambiente `ensam` (si no está activado ya) antes de ejecutar los comandos de esta guía:
>
> ```
> mamba activate ensam
> ```

Para empezar a descargar las muestras, abra una terminal y ejecute las órdenes que se dan a continuación.

> **Advertencia**
>
> Siempre que vea comentarios (líneas empezando con `#`) en las cajas de comandos, no los digite en la terminal. Estos comentarios solo proveen información adicional a cerca de cada comando.

> **Nota**
>
> - La descarga de cada muestra toma aproximadamente cinco minutos (o más), dependiendo de la velocidad de su conexión a Internet. No se preocupe si no ve ningún avance aparente después de ejecutar el comando de descarga (`fasterq-dump`).
> - Si quiere ver el progreso de cada descarga, use la opción `-p` (o `--progress`) con `fasterq-dump`
> - Puede ver otras opciones útiles de `fasterq-dump` consultando la ayuda: `fasterq-dump --help`

```
# Entrar al directorio para datos en el directorio del proyecto
cd $HOME/proyectos/ensamblaje/datos

# Descargar las muestras
fasterq-dump -S SRR22388518
```

```
spots read      : 870,940
reads read      : 1,741,880
reads written   : 1,741,880
```

Finalizada la descarga `fasterq-dump` imprime en pantalla el resumen de las secuencias descargadas y escritas en archivos (salida anterior) .

Ahora verifique los archivos descargados:

```
ls -lh
```

```
total 962M
-rw-rw-r-- 1 hector hector 481M mar  2 14:40 SRR22388518_1.fastq
-rw-rw-r-- 1 hector hector 481M mar  2 14:40 SRR22388518_2.fastq
```

Como puede observar, hay dos archivos descargados con la extensión `.fastq`. Veamos la estructura de nombre de los archivos descargados:

```
   SRR22388518       _          1              .        fastq
       |                        |                         |
(accession number)     (conjunto de secuencias)     (extensión de archivo)
```

> **!** Importante
>
> Hay dos archivos puesto que la muestra se secuenció con tecnología Illumina *paired-end*, en la cual resultan dos *reads* (secuencias), *forward* (`_1`) y *reverse* (`_2`), de secuenciar los extremos de una molécula de ADN. En la Figura 2.1 se detalla la ubicación relativa de los dos *reads* respecto del fragmento de ADN secuenciado. En el archivo `_1` están guardas todas las secuencias *forward* y en el archivo `_2`, todas las secuencias *reverse*.

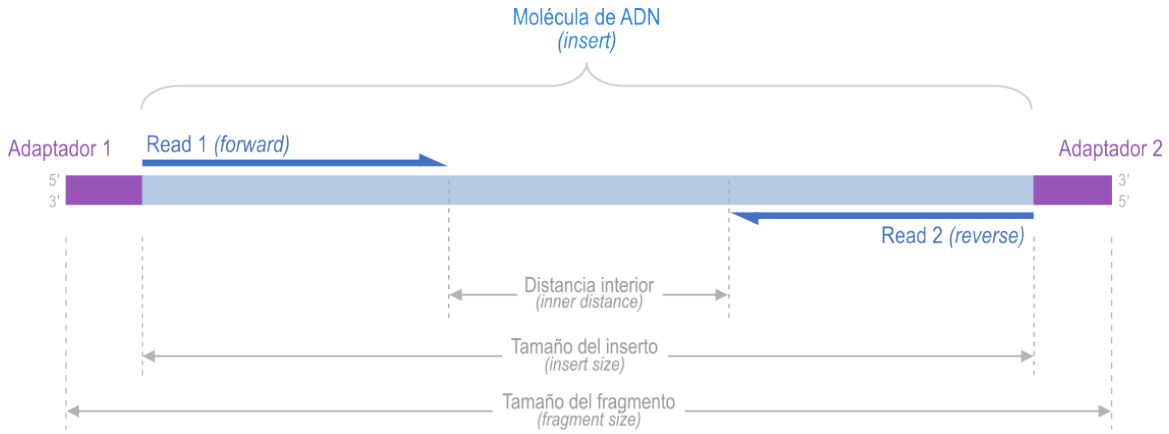

Figura 2.1: Representación esquemática de la secuenciación *paired-end*.

El formato FASTQ[2] (Cock et al. 2010) es el estándar *de facto* para datos de secuenciación de segunda generación y es usado, entre otras, por la tecnología Illumina. Este formato almacena tanto las secuencias de ADN como la calidad de cada base secuenciada.

Ahora descarguemos el resto de las muestras:

```
fasterq-dump -S SRR22388519

fasterq-dump -S SRR18335437

fasterq-dump -S SRR18335438
```

[2] Wikipedia: FASTQ Format

Ahora, aunque no es necesario, es una buena práctica comprimir las archivos descargados para que ocupen menos espacio en disco:

```
gzip *.fastq
```

Como verá, ahora los archivos están comprimidos por lo que tienen la extensión `.gz` (`.fastq.gz`):

```
ls
```

```
SRR18335437_1.fastq.gz  SRR18335438_2.fastq.gz  SRR22388519_1.fastq.gz
SRR18335437_2.fastq.gz  SRR22388518_1.fastq.gz  SRR22388519_2.fastq.gz
SRR18335438_1.fastq.gz  SRR22388518_2.fastq.gz
```

Finalmente, regresemos al directorio de proyectos:

```
cd $HOME/proyectos
```

3 Control de calidad y limpieza de datos

Una vez descargados los datos, el siguiente paso consiste en hacer control de calidad y limpieza de los datos. En este paso primero se revisa la calidad de los datos, y luego se editan o eliminan las lecturas (*reads*) que no tienen la calidad necesaria para conseguir un buen ensamblaje.

> **!** Importante
>
> Es importante comprender la calidad de los datos de secuenciación. Puede aprender sobre el puntaje Phred y cómo se codifica en el formato FASTQ en los artículos de Wikipedia *"Nivel de calidad Phred"* y *"FASTQ format"*, respectivamente.

3.1 Software requerido

Software	Versión	Descripción	Ref.
FastQC	0.12.1	Herramienta para el control de calidad en datos de secuenciación de alto rendimiento	Sitio Web
MultiQC	1.14	Herramienta para unificar y resumir múltiples reportes generados por FastQC y muchos otros programas de bioinformática.	Ewels et al. (2016); sitio Web
fastp	0.23.2	Herramienta para el pre-procesamiento rápido de archivos Fastq.	Chen et al. (2018); repositorio GitHub

3.2 Determinación de calidad

Para revisar la calidad de los datos descargados, usaremos `fastqc`:

```
# Entrar al directorio de datos en la carpeta del proyecto ensamblaje
cd $HOME/proyectos/ensamblaje/datos
# Analizar todos los archivos descargados
fastqc -o qc/fastqc *.fastq.gz
```

A continuación verá mensajes de progreso de `fastqc`:

```
Started analysis of SRR18335437_1.fastq.gz
Approx 5% complete for SRR18335437_1.fastq.gz
Approx 10% complete for SRR18335437_1.fastq.gz
Approx 15% complete for SRR18335437_1.fastq.gz
Approx 20% complete for SRR18335437_1.fastq.gz
Approx 25% complete for SRR18335437_1.fastq.gz
Approx 30% complete for SRR18335437_1.fastq.gz
Approx 35% complete for SRR18335437_1.fastq.gz
Approx 40% complete for SRR18335437_1.fastq.gz
Approx 45% complete for SRR18335437_1.fastq.gz
Approx 50% complete for SRR18335437_1.fastq.gz
Approx 55% complete for SRR18335437_1.fastq.gz
Approx 60% complete for SRR18335437_1.fastq.gz
Approx 65% complete for SRR18335437_1.fastq.gz
Approx 70% complete for SRR18335437_1.fastq.gz
Approx 75% complete for SRR18335437_1.fastq.gz
Approx 80% complete for SRR18335437_1.fastq.gz
Approx 85% complete for SRR18335437_1.fastq.gz
Approx 90% complete for SRR18335437_1.fastq.gz
Approx 95% complete for SRR18335437_1.fastq.gz
Analysis complete for SRR18335437_1.fastq.gz
...
```

Al final, por cada archivo `.fastq` analizado, `fastqc` genera un archivo `.html` con el reporte de calidad y un archivo comprimido (`.zip`):

```
ls qc/fastqc
```

```
SRR18335437_1_fastqc.html  SRR18335438_2_fastqc.html  SRR22388519_1_fastqc.html
SRR18335437_1_fastqc.zip   SRR18335438_2_fastqc.zip   SRR22388519_1_fastqc.zip
SRR18335437_2_fastqc.html  SRR22388518_1_fastqc.html  SRR22388519_2_fastqc.html
SRR18335437_2_fastqc.zip   SRR22388518_1_fastqc.zip   SRR22388519_2_fastqc.zip
SRR18335438_1_fastqc.html  SRR22388518_2_fastqc.html
SRR18335438_1_fastqc.zip   SRR22388518_2_fastqc.zip
```

> **Nota**
>
> El archivo comprimido `.zip` contiene una copia del reporte `.html`, gráficos, y archivos de estadísticas.

3.2.1 Reporte de calidad FastQC

Analicemos uno de los reportes de calidad de FastQC. Abra el archivo `SRR18335437_1_fastqc.html`. El reporte contiene diferentes secciones, llamadas módulos, que corresponden a diferentes evaluaciones de calidad que la herramienta hace sobre los datos (Figura 3.1). Puede consultar información detallada (en inglés) a cerca de FastQC y sus módulos en el Apéndice A. Por cada módulo, el reporte presenta un ícono con tres posibles estados de acuerdo al resultado de la evaluación (Tabla 3.2).

Tabla 3.2: Posibles resultados de la evaluación de calidad realizada por la herramienta FastQC

Símbolo	Descripción
	Pasó. La muestra pasó la evaluación de calidad en esta categoría (módulo). No hay problemas de calidad.
	Advertencia. La muestra tiene un posible problema calidad. El usuario debería revisar la muestra y tomar las medidas necesarias para evitar el error de ser posible. Por la naturaleza de la secuenciación de ADN, es normal que se presenten advertencias en algunos módulos en las muestras sin que signifique que haya un problema real o grave.
	Falló. La muestra falló la evaluación de calidad en este módulo. El usuario debería limpiar los datos para corregir el error.

De acuerdo con los estados, vemos que las muestras fallaron las evaluaciones de calidad de los módulos *"Per base sequence quality"* y *"Sequence Duplication Levels"*, y el módulo *"Sequence Length Distribution"* tiene una advertencia (Figura 3.1).

Tal vez el módulo más importante a revisar es *"Per base sequence quality"* (Sección A.3.5), el cual muestra el valor de calidad de por cada posición a lo largo de las secuencias del archivo procesado. Típicamente en archivos producidos con tecnología Illumina, la calidad es baja en las primeras siete a 10 bases de las secuencias, incrementando hasta alcanzar su máximo hacia la parte media de la secuencia. Luego la calidad empieza a decrecer hasta encontrar sus mínimos valores al final de la secuencia. Comúnmente la calidad mínima para lograr ensamblajes decentes es $Q \geq 20$ (eje Y en el gráfico). Así, este gráfico el crucial para que el usuario decida el número de bases (eje X) que se recortarán en los extremos de las secuencias (inicio 5'; final 3'), los cuales típicamente contienen las secciones con menor calidad.

3.2.2 Unificando los reportes de calidad

Dado que los reportes de FastQC son independientes por cada archivo de lecturas (`_1` y `_2`) y cada muestra, es difícil tener una visión general de la calidad de todos los datos en conjunto.

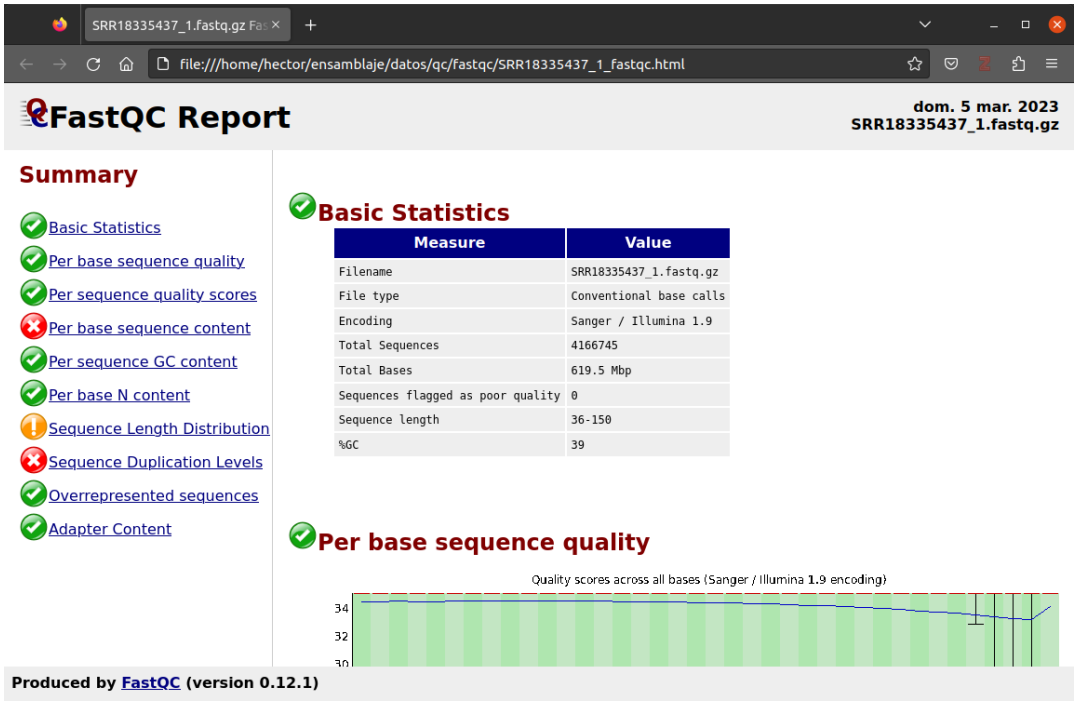

Figura 3.1: Captura de pantalla de un reporte de calidad generado con la aplicación FastQC.

Conviene entonces unificar los datos de calidad en un solo reporte para lograr una mejor interpretación de la información.

Esta unificación se logra con la aplicación MultiQC. Ejecute la siguiente orden:

```
multiqc --filename multiqc_report.html --outdir qc qc/fastqc
```

```
  /// MultiQC 🔍 | v1.14

|           multiqc | Search path : /home/hector/proyectos/ensamblaje/datos/qc/
    fastqc
|         searching | ━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━━ 100% 16/16
|            fastqc | Found 8 reports
|           multiqc | Compressing plot data
|           multiqc | Report      : qc/multiqc_report.html
|           multiqc | Data        : qc/multiqc_report_data
|           multiqc | MultiQC complete
```

Ahora MultiQC ha generado dos elementos, el archivo `multiqc_report.html` y un directorio `multiqc_report_data` que contiene archivos de estadísticas. Al abrir el reporte `.html` se puede ver la información de calidad de todos los archivos analizados con FastqQC (Figura 3.2).

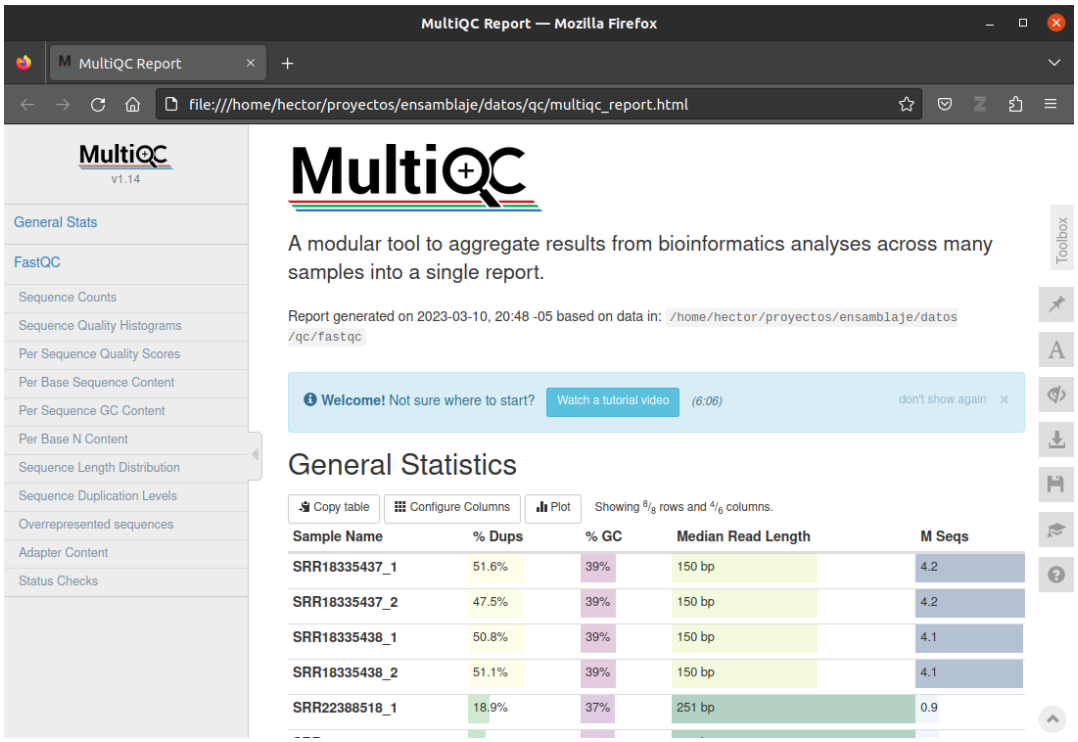

Figura 3.2: Captura de pantalla del reporte de calidad unificado generado con MultiQC.

> **Tip**
>
> Abra el reporte `ensamblaje/datos/qc/multiqc_report.html` para revisar toda la información de calidad evaluada por FastQC.

Revisando la sección *"General Statistics"* del reporte MultiQC, podemos observar que los tamaños de secuencia varían según la muestra. La longitud (mediana) de secuencias de las muestras `SRR18335437` y `SRR18335438` es de 150 bp, mientras que la de las muestras `SRR22388518` y `SRR22388518` es de 251 bp.

Echemos un vistazo ahora al gráfico de calidad de secuenciación en la sección *"Sequence Quality Histograms"* (Figura 3.3). Además de la diferencia de longitud de secuencias, se puede notar que:

- La calidad al inicio de las secuencias en todos los archivos es buena ($Q \geq 30$)
- La calidad al final de las secuencias es aceptable ($Q \geq 20$) en todos los archivos, con excepción de las secuencias *reverse* (`_2`) de las muestras `SRR22388518` y `SRR22388519`.

De estas observaciones se puede concluir que la limpieza de los datos consistirá en recortar las últimas bases (aprox. 20) de los archivos `SRR22388518_2.fastq.gz` y `SRR22388519_2.fastq.gz` pues son las que presentan baja calidad. Además, como buena práctica, se eliminarán aquellas secuencias cuya calidad promedio sea $Q < 20$.

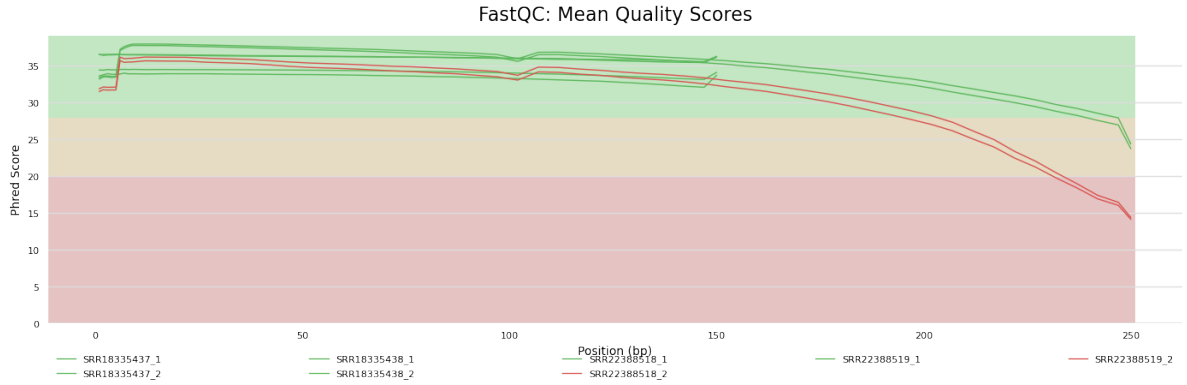

Figura 3.3: Gráfico de calidad de secuenciación por base

3.3 Limpieza

Usaremos la aplicación fastp para recortar y filtrar las secuencias por calidad. Empecemos procesando la primera muestra:

```
# Entrar al directorio raíz del proyecto (en mi caso, /home/hector/ensamblaje)
cd ..

# Comando para ejecutar la limpieza de la primera muestra
fastp --verbose \
      --thread 4 \
      --detect_adapter_for_pe \
      --cut_tail \
      --cut_mean_quality 20 \
      --average_qual 20 \
      --report_title 'Reporte fastp: SRR22388518' \
      --in1 datos/SRR22388518_1.fastq.gz \
      --in2 datos/SRR22388518_2.fastq.gz \
      --out1 resultados/00_datos_limpios/SRR22388518_1.clean.fastq.gz \
      --out2 resultados/00_datos_limpios/SRR22388518_2.clean.fastq.gz \
      --unpaired1 resultados/00_datos_limpios/SRR22388518_1.unpaired.fastq.gz \
      --unpaired2 resultados/00_datos_limpios/SRR22388518_2.unpaired.fastq.gz \
      --html resultados/00_datos_limpios/qc/fastp/SRR22388518.report.fastp.html \
      --json resultados/00_datos_limpios/qc/fastp/SRR22388518.report.fastp.json
```

Antes de revisar el resultado, veamos las opciones usadas con el comando y su finalidad:

- `--verbose`: provee información adicional durante el procesamiento de los archivos
- `--thread 4`: usa cuatro hilos de ejecución de manera paralela para acelerar el procesamiento de los archivos
- `--detect_adapter_for_pe`: detecta las secuencias de adaptadores de secuenciación y las elimina
- `--cut_tail`: corta la "cola" (*tail*) de las secuencias, la cual se dijo tiene las bases de más baja calidad
- `--cut_mean_quality 20`: la calidad media mínima aceptada para corte de secuencias. fastp usa una ventana de 4 bases desde el extremo de la secuencia para revisar calidad; si el promedio de estas cuatro bases está por debajo de 20, elimina este extremo.
- `--average_qual 20`: la calidad media mínima aceptada para mantener una secuencia. Si al calcular la calidad media de toda la secuencia está por debajo de 20, la secuencia es descartada.
- `--report_title 'Reporte fastp: SRR22388518'`: el título del reporte
- `--in1`: el archivo de secuencias *forward* a ser procesado
- `--in2`: el archivo de secuencias *reverse* a ser procesado
- `--out1`: el archivo de salida con las secuencias *forward* que pasaron el control de calidad
- `--out2`: el archivo de salida con las secuencias *reverse* que pasaron el control de calidad
- `--unpaired1`: el archivo de salida con las secuencias *forward* no pareadas que pasaron el control de calidad (no tienen una secuencia par *reverse*)

- `--unpaired2`: el archivo de salida con las secuencias *reverse* no pareadas que pasaron el control de calidad (no tienen una secuencia par *forward*)
- `--html`: el archivo de reporte en formato html
- `--json`: el archivo de reporte en formato json (estadísticas)

> **Tip**
>
> Para conocer todas las opciones disponibles de fastp consulte la ayuda ejecutando `fastp --help`.

En el anterior comando, en lugar de cortar un número determinado de bases al final de las secuencias, se usa la estrategia del programa fastp. Por cada secuencia del archivo, fastp revisa la calidad media de una pequeña porción de 4 bases, llamado ventana, empezando desde el extremo final. Si la calidad media está por debajo del mínimo definido (20 en este caso), fastp recorta esta ventana de la secuencia. Este proceso se repita hasta que no se encuentre una ventana que deba recortarse. Así, solo las secuencias con baja calidad al final son recortadas. Este mismo principio se puede aplicar para el inicio de las secuencias, cuando sea el caso.

Veamos ahora el resultado de fastp. Al ejecutar el anterior comando veremos una salida parecida a esto:

```
Detecting adapter sequence for read1...
>Illumina TruSeq Adapter Read 1
AGATCGGAAGAGCACACGTCTGAACTCCAGTCA

Detecting adapter sequence for read2...
No adapter detected for read2

[19:24:32] start to load data of read1
[19:24:32] start to load data of read2
[19:24:36] Read1: loading completed with 871 packs
[19:24:36] Read2: loading completed with 871 packs
[19:24:39] thread 4 data processing completed
[19:24:39] thread 4 finished
[19:24:39] thread 3 data processing completed
[19:24:39] thread 3 finished
[19:24:39] thread 2 data processing completed
[19:24:39] thread 2 finished
[19:24:39] thread 1 data processing completed
[19:24:39] thread 1 finished
[19:24:39] resultados/00_datos_limpios/SRR22388518_1.unpaired.fastq.gz writer
    finished
[19:24:39] resultados/00_datos_limpios/SRR22388518_2.unpaired.fastq.gz writer
    finished
```

```
[19:24:40] resultados/00_datos_limpios/SRR22388518_2.clean.fastq.gz writer finished
[19:24:40] resultados/00_datos_limpios/SRR22388518_1.clean.fastq.gz writer finished
[19:24:40] start to generate reports

Read1 before filtering:
total reads: 870940
total bases: 218350507
Q20 bases: 198719240(91.0093%)
Q30 bases: 184185641(84.3532%)

Read2 before filtering:
total reads: 870940
total bases: 218399177
Q20 bases: 175386628(80.3055%)
Q30 bases: 149084629(68.2624%)

Read1 after filtering:
total reads: 863093
total bases: 209876970
Q20 bases: 193175278(92.0422%)
Q30 bases: 180122777(85.823%)

Read2 after filtering:
total reads: 863093
total bases: 201834951
Q20 bases: 170111238(84.2823%)
Q30 bases: 146895463(72.78%)

Filtering result:
reads passed filter: 1726186
reads failed due to low quality: 12556
reads failed due to too many N: 488
reads failed due to too short: 2650
reads with adapter trimmed: 150684
bases trimmed due to adapters: 7399476

Duplication rate: 0.0137782%

Insert size peak (evaluated by paired-end reads): 251

JSON report: resultados/00_datos_limpios/qc/fastp/report.fastp.json
HTML report: resultados/00_datos_limpios/qc/fastp/report.fastp.html
```

```
fastp --verbose --thread 4 --detect_adapter_for_pe --cut_tail --cut_mean_quality 20
     --average_qual 20 --report_title Reporte fastp: SRR22388518 --in1 datos/
    SRR22388518_1.fastq.gz --in2 datos/SRR22388518_2.fastq.gz --out1 resultados/00
    _datos_limpios/SRR22388518_1.clean.fastq.gz --out2 resultados/00_datos_limpios/
    SRR22388518_2.clean.fastq.gz --unpaired1 resultados/00_datos_limpios/
    SRR22388518_1.unpaired.fastq.gz --unpaired2 resultados/00_datos_limpios/
    SRR22388518_2.unpaired.fastq.gz --html resultados/00_datos_limpios/qc/fastp/
    SRR22388518.report.fastp.html --json resultados/00_datos_limpios/qc/fastp/
    SRR22388518.report.fastp.json
fastp v0.23.2, time used: 22 seconds
```

Podemos encontrar información importante en los mensajes de la salida, como por ejemplo el número de secuencias y calidad antes y después de aplicar la limpieza o filtrado (secciones `Read1 before filtering:`, `Read2 before filtering:`, `Read1 after filtering:` y `Read2 after filtering:`), y el resumen del número de reads que pasaron y no pasaron el filtro (sección `Filtering result`).

Junto con los archivos de secuencias filtradas, fastp genera un archivo de reporte `.html` y un archivo de estadísticas.

Ahora se deben procesar el resto de los archivos:

```
fastp --verbose \
      --thread 4 \
      --detect_adapter_for_pe \
      --cut_tail \
      --cut_mean_quality 20 \
      --average_qual 20 \
      --report_title 'Reporte fastp: SRR22388519' \
      --in1 datos/SRR22388519_1.fastq.gz \
      --in2 datos/SRR22388519_2.fastq.gz \
      --out1 resultados/00_datos_limpios/SRR22388519_1.clean.fastq.gz \
      --out2 resultados/00_datos_limpios/SRR22388519_2.clean.fastq.gz \
      --unpaired1 resultados/00_datos_limpios/SRR22388519_1.unpaired.fastq.gz \
      --unpaired2 resultados/00_datos_limpios/SRR22388519_2.unpaired.fastq.gz \
      --html resultados/00_datos_limpios/qc/fastp/SRR22388519.report.fastp.html \
      --json resultados/00_datos_limpios/qc/fastp/SRR22388519.report.fastp.json

fastp --verbose \
      --thread 4 \
      --detect_adapter_for_pe \
      --cut_tail \
      --cut_mean_quality 20 \
      --average_qual 20 \
```

```
      --report_title 'Reporte fastp: SRR18335437' \
      --in1 datos/SRR18335437_1.fastq.gz \
      --in2 datos/SRR18335437_2.fastq.gz \
      --out1 resultados/00_datos_limpios/SRR18335437_1.clean.fastq.gz \
      --out2 resultados/00_datos_limpios/SRR18335437_2.clean.fastq.gz \
      --unpaired1 resultados/00_datos_limpios/SRR18335437_1.unpaired.fastq.gz \
      --unpaired2 resultados/00_datos_limpios/SRR18335437_2.unpaired.fastq.gz \
      --html resultados/00_datos_limpios/qc/fastp/SRR18335437.report.fastp.html \
      --json resultados/00_datos_limpios/qc/fastp/SRR18335437.report.fastp.json

fastp --verbose \
      --thread 4 \
      --detect_adapter_for_pe \
      --cut_tail \
      --cut_mean_quality 20 \
      --average_qual 20 \
      --report_title 'Reporte fastp: SRR18335438' \
      --in1 datos/SRR18335438_1.fastq.gz \
      --in2 datos/SRR18335438_2.fastq.gz \
      --out1 resultados/00_datos_limpios/SRR18335438_1.clean.fastq.gz \
      --out2 resultados/00_datos_limpios/SRR18335438_2.clean.fastq.gz \
      --unpaired1 resultados/00_datos_limpios/SRR18335438_1.unpaired.fastq.gz \
      --unpaired2 resultados/00_datos_limpios/SRR18335438_2.unpaired.fastq.gz \
      --html resultados/00_datos_limpios/qc/fastp/SRR18335438.report.fastp.html \
      --json resultados/00_datos_limpios/qc/fastp/SRR18335438.report.fastp.json
```

3.4 Verificación de calidad después de la limpieza

Finalmente podemos usar FastQC y MultiQC para revisar la calidad de las muestras después de la limpieza:

```
# Generar reportes con FastQC
fastqc -o resultados/00_datos_limpios/qc/fastqc resultados/00_datos_limpios/*.clean
    .fastq.gz

# Generar reporte unificado con MultiQC
multiqc \
  --filename multiqc_report.html \
  --outdir resultados/00_datos_limpios/qc \
  resultados/00_datos_limpios/qc/fastp \
  resultados/00_datos_limpios/qc/fastqc
```

Note que en el anterior comando de MultiQC se pasó no solo el directorio de reportes FastQC, sino también el directorio con los reportes de fastp. La aplicación se encarga de generar un solo documento `.html` con dos secciones, una para fastp y otra para FastQC.

> **Tip**
>
> Explore el reporte `resultados/00_datos_limpios/qc/multiqc_report.html` para ver las diferentes estadísticas de calidad después de haber aplicado los filtros a las muestras.

Echemos un vistazo al gráfico de calidad de secuenciación por base generado sobre los datos limpios (Figura 3.3). Podemos ver que las dos muestras que te tenían baja calidad hacia el final de las secuencias, ahora aparecen en color naranja, con una calidad $Q > 20$.

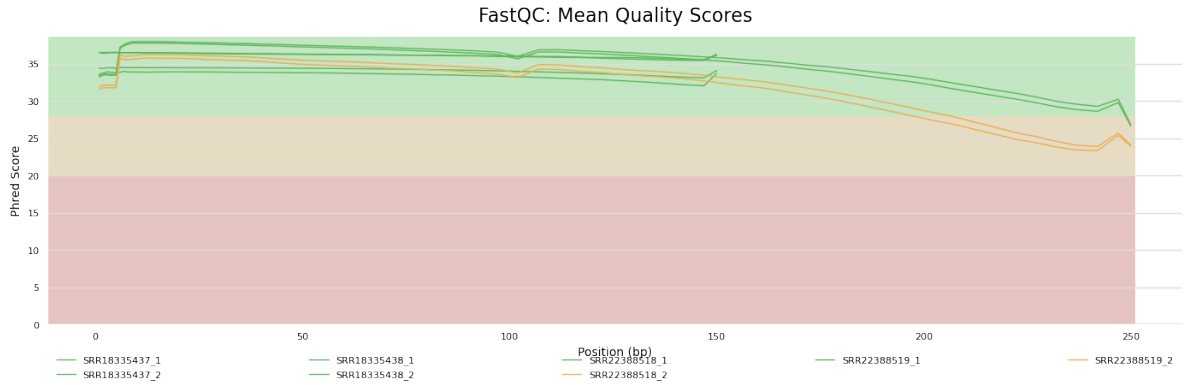

Finalmente las muestras están listas para ser ensambladas.

4 Ensamblaje

Ahora que los datos están depurados, podemos ensamblar las muestras en sus correspondientes genomas

4.1 Software requerido

Software	Versión	Descripción	Ref.
SPAdes	3.15.5	Conjunto de herramientas para ensamblaje *de novo* de genomas con múltiples flujos de trabajo de ensamblaje especializado.	Prjibelski et al. (2020); Sitio Web; repositorio GitHub

4.2 Ensamblaje de genomas

Usaremos el ensamblador *de novo*[1] SPAdes (Prjibelski et al. 2020), el cual fue desarrollado inicialmente para ensamblar secuencias cortas Illumina obtenidas de aislamientos bacterianos y secuenciación de células individuales (*single-cell sequencing*), y que con el tiempo ha sido extendido para usar secuencias de otras tecnologías y ensamblar metagenomas, transcriptomas, y plásmidos.

Para ensamblar la muestra ejecute la siguiente orden:

```
# Entrar en el directorio raíz del proyecto
cd ensamblaje
# Ejecutar el ensamblaje
spades.py \
  --isolate \
  -1 resultados/00_datos_limpios/SRR22388518_1.clean.fastq.gz \
```

[1] Wikipedia - De novo assemblers: https://en.wikipedia.org/wiki/De_novo_sequence_assemblers

```
  -2 resultados/00_datos_limpios/SRR22388518_2.clean.fastq.gz \
  -o resultados/01_ensamblaje/SRR22388518 \
  -t 4
```

Veamos los parámetros usados en el comando anterior:

- `--isolate`: indica a SPAdes que el pipeline a ser ejecutado es el de ensamblaje de aislamientos bacterianos.
- `-1`: archivo con los *reads forward*
- `-2`: archivo con los *reads reverse*
- `-o`: directorio donde se almacenarán los archivos de salida
- `-t`: hilos (*threads*) de procesos en paralelo para incrementar la velocidad del ensamblaje

El tiempo de ensamblaje depende del tamaño de la muestra a ensamblar, es decir de número de *reads* en los archivos `.fastq.gz` de entrada, y del número de *cores* o procesadores del computador y los hilos asignados al comando (opción `-t`). En el caso anterior el proceso tomó 35 minutos para ensamblar un total de 1726.186 de *reads* (863093 $\times$ 2) usando 4 hilos en una máquina con ocho *cores*.

Ahora veamos la salida del comando:

```
Command line: /home/hector/mambaforge/envs/ensam/bin/spades.py  --isolate   -1  /
    home/hector/proyectos/ensamblaje/resultados/00_datos_limpios/SRR22388518_1.
    clean.fastq.gz  -2  /home/hector/proyectos/ensamblaje/resultados/00
    _datos_limpios/SRR22388518_2.clean.fastq.gz  -o  /home/hector/proyectos/
    ensamblaje/resultados/01_ensamblaje/SRR22388518  -t  4

System information:
  SPAdes version: 3.15.5
  Python version: 3.10.6
  OS: Linux-5.15.0-67-generic-x86_64-with-glibc2.31

Output dir: /home/hector/proyectos/ensamblaje/resultados/01_ensamblaje/SRR22388518
Mode: ONLY assembling (without read error correction)
Debug mode is turned OFF

Dataset parameters:
  Isolate mode
  Reads:
    Library number: 1, library type: paired-end
      orientation: fr
```

```
      left reads: ['/home/hector/proyectos/ensamblaje/resultados/00_datos_limpios/
          SRR22388518_1.clean.fastq.gz']
      right reads: ['/home/hector/proyectos/ensamblaje/resultados/00_datos_limpios/
          SRR22388518_2.clean.fastq.gz']
      interlaced reads: not specified
      single reads: not specified
      merged reads: not specified
Assembly parameters:
  k: automatic selection based on read length
  Repeat resolution is enabled
  Mismatch careful mode is turned OFF
  MismatchCorrector will be SKIPPED
  Coverage cutoff is turned OFF
Other parameters:
  Dir for temp files: /home/hector/proyectos/ensamblaje/resultados/01_ensamblaje/
      SRR22388518/tmp
  Threads: 4
  Memory limit (in Gb): 7


======= SPAdes pipeline started. Log can be found here: /home/hector/proyectos/
    ensamblaje/resultados/01_ensamblaje/SRR22388518/spades.log

...

===== Terminate finished.

 * Assembled contigs are in /home/hector/proyectos/ensamblaje/resultados/01
     _ensamblaje/SRR22388518/contigs.fasta
 * Assembled scaffolds are in /home/hector/proyectos/ensamblaje/resultados/01
     _ensamblaje/SRR22388518/scaffolds.fasta
 * Paths in the assembly graph corresponding to the contigs are in /home/hector/
     proyectos/ensamblaje/resultados/01_ensamblaje/SRR22388518/contigs.paths
 * Paths in the assembly graph corresponding to the scaffolds are in /home/hector/
     proyectos/ensamblaje/resultados/01_ensamblaje/SRR22388518/scaffolds.paths
 * Assembly graph is in /home/hector/proyectos/ensamblaje/resultados/01_ensamblaje/
     SRR22388518/assembly_graph.fastg
 * Assembly graph in GFA format is in /home/hector/proyectos/ensamblaje/resultados
     /01_ensamblaje/SRR22388518/assembly_graph_with_scaffolds.gfa

======= SPAdes pipeline finished.

SPAdes log can be found here: /home/hector/proyectos/ensamblaje/resultados/01
```

```
    _ensamblaje/SRR22388518/spades.log

Thank you for using SPAdes!
```

En la salida anterior, se puede observar al principio el comando ejecutado, así como información del sistema y la ubicicaión de los datos de entrada y salida. `spades.py` indica el inicio del ensamblaje mediante el encabezado `=== SPAdes pipeline started.` y presenta la ubicación del archivo *log* (`Log can be found here: /home/hector/proyectos/ensamblaje/resultados/01_ensamblaje/SRR22388518/spades.log`). Este archivo *log* es muy importante pues contiene toda la información del proceso del ensamblaje, incluido cualquier error que se haya presentado, lo que permite tomar acciones para corregirlo. `spades.py` también detalla el proceso de ensamblaje a través de una amplia serie de mensajes ubicados en lugar de los tres puntos `...` en la salida anterior. Cuando el proceso de ensamblaje es exitoso, `spades.py` presenta la sección `=== Terminate finished.` que contiene la ubicación de los archivos de salida. Finalmente, bajo la sección `=== SPAdes pipeline finished.`, el programa presenta de nuevo la ubicación del archivo *log*.

Examinemos ahora el directorio de salida de SPAdes:

```
ls resultados/01_ensamblaje/SRR22388518
```

```
assembly_graph_after_simplification.gfa
assembly_graph.fastg
assembly_graph_with_scaffolds.gfa
before_rr.fasta
contigs.fasta
contigs.paths
dataset.info
input_dataset.yaml
K127
K21
K33
K55
K77
K99
misc
params.txt
pipeline_state
run_spades.sh
run_spades.yaml
scaffolds.fasta
scaffolds.paths
spades.log
```

```
tmp
```

Estos son los archivos de salida cuando el ensamblaje es exitoso:

- `contigs.fasta`: las secuencias de los *contigs*[2] (en español, llamado menos frecuentemente como cóntigo) en formato FASTA[3]
- `scaffolds.fasta`: las secuencias de *scaffolds*[4] en formato FASTA
- `assembly_graph.gfa`: grafo de ensamblaje y los camios de los *scaffolds* en formato GFA 1.0[5]
- `assembly_graph.fastg`: grafo del ensamblaje en formato FASTG
- `contigs.paths`: caminos de los *contigs* en el grafo de ensamblaje
- `scaffolds.paths`: caminos de los *scaffolds* en el grafo de ensamblaje
- `spades.log`: archivo con todos los mensajes del proceso

Dado que SPAdes es un ensamblador de genomas basado en grafos de De Bruijn[6] (Compeau, Pevzner, y Tesler 2011), algunos de los archivos de salida contienen información de los grafos usados durante el ensamblaje (con extensión `.gfa` y `.fastg`). Si desea visualizar los archivos de grafos puede usar la aplicación Bandage[7] (Wick et al. 2015).

Los archivos de salida más importantes son aquellos que contienen las secuencias del ensamblaje en sí, es decir los *contigs* y *scaffolds* en formato FASTA (`.fasta`). Los *scaffolds* son las secuencias más largas de ensamblaje, las cuales son creadas a partir de las secuencias de los *contigs*. Este es el archivo que se usará como resultado final del ensamblaje y por lo tanto anotado.

Veamos las primeras 10 líneas del archivo `scaffolds.fasta`:

```
head resultados/01_ensamblaje/SRR22388518/scaffolds.fasta
```

```
>NODE_1_length_407393_cov_61.379170
GCTCTGTTGAATGATTTATCCAAAAATCGTTTAGCAACTAGCAAGGTTGAACTAGGAATA
CAACAAAAATCCTAAATTAAGAGAATTTTATAGCTTTTTATAGGATTTTATAGGTTTGTA
GTAACGGTATTTTGGGCAAGAAATCAACCTGACCACTTACAACCTTTGCCGCATCAACAT
GTTTTTGCATGACATCAATTACTCTAAATTCCACATTGCGCTAGGGGACACGCTTTTAGA
TCCAAAACATGAAGACGATGAGCCTTTTGATGCGATCGTTTCCAACCCTCCTTATTCCAC
TAAATGGGTGGGCGATAACAACCCTATTTTAATCAACGACGAGCGCTTTAGCCCGGCCGG
TGTGCTAGCGCCCAAAAACGCCGCCGATCTCGCTTTCACCATGCACATGCTTTCTTATTT
ATCCAATAGCGGCACGGCTGCGATCGTGGAATTCCCCGGGGGTGCTTTATAGGGGGAATGC
TGAAGCAAAAATCAGAGAATATTTAGTCAAAGAAAATTTCATTGACTGCGTGATCGCTTT
```

[2] Wikipedia - Cóntigo: https://es.wikipedia.org/wiki/C%C3%B3ntigo
[3] Wikipedia - Formato FASTA: https://es.wikipedia.org/wiki/Formato_FASTA
[4] Wikipedia - *Scaffolding (bioinformatics)*: https://en.wikipedia.org/wiki/Scaffolding_(bioinformatics)
[5] *The GFA Format Specification*: https://gfa-spec.github.io/GFA-spec/GFA1.html
[6] Wikipedia - Grafo de De Bruijn: https://es.wikipedia.org/wiki/Grafo_de_De_Bruijn
[7] Bandage: http://rrwick.github.io/Bandage/

En el identificador (nombre) del primer *scaffold* `>NODE_1_length_407393_cov_61.379170`, se puede observar alguna información de la secuencia: `1` es el número del *contig/scaffold*, 407393 es la longitud de la secuencia en pares de bases (bp), y 61.379170 es el número de *k*-mers que cubren el *scaffold*.

Con un simple comando podemos averiguar el número total de *scaffolds* en el ensamblaje:

```
grep -c '>' resultados/01_ensamblaje/SRR22388518/scaffolds.fasta
```

```
336
```

Ahora terminaremos de procesar el conjunto de datos ensambando el resto de las muestras:

```
spades.py \
  --isolate \
  -1 resultados/00_datos_limpios/SRR22388519_1.clean.fastq.gz \
  -2 resultados/00_datos_limpios/SRR22388519_2.clean.fastq.gz \
  -o resultados/01_ensamblaje/SRR22388519 \
  -t 4

spades.py \
  --isolate \
  -1 resultados/00_datos_limpios/SRR18335437_1.clean.fastq.gz \
  -2 resultados/00_datos_limpios/SRR18335437_2.clean.fastq.gz \
  -o resultados/01_ensamblaje/SRR18335437 \
  -t 4

spades.py \
  --isolate \
  -1 resultados/00_datos_limpios/SRR18335438_1.clean.fastq.gz \
  -2 resultados/00_datos_limpios/SRR18335438_2.clean.fastq.gz \
  -o resultados/01_ensamblaje/SRR18335438 \
  -t 4
```

Para que cada ensamblaje (`scaffolds.fasta`) tenga el nombre de la correspondiente muestra, crearemos enlaces simbólicos en el directorio `resulltados/01_ensamblaje`. Por ejemplo, dentro del directorio `resultados/01_ensamblaje` el archivo `SRR22388518.fasta` apuntará al archivo `SRR22388519/scaffolds.fasta`. Esto se hace para que los pasos siguientes de la guía (control de calidad y anotación) se ejecuten con mayor comodidad. Para crear los enlaces ejecute la siguientes órdenes:

```
ln -sr resultados/01_ensamblaje/SRR22388518/scaffolds.fasta \
  resultados/01_ensamblaje/SRR22388518.fasta
```

```
ln -sr resultados/01_ensamblaje/SRR22388519/scaffolds.fasta \
  resultados/01_ensamblaje/SRR22388519.fasta

ln -sr resultados/01_ensamblaje/SRR18335437/scaffolds.fasta \
  resultados/01_ensamblaje/SRR18335437.fasta

ln -sr resultados/01_ensamblaje/SRR18335438/scaffolds.fasta \
  resultados/01_ensamblaje/SRR18335438.fasta
```

Verifiquemos los enlaces creados:

```
ls -l resultados/01_ensamblaje
```

```
total 16K
drwxrwxr-x  9 hector hector 4,0K mar 12 19:33 SRR18335437
lrwxrwxrwx  1 hector hector   27 mar 12 18:54 SRR18335437.fasta -> SRR18335437/
    scaffolds.fasta
drwxrwxr-x  9 hector hector 4,0K mar 12 19:57 SRR18335438
lrwxrwxrwx  1 hector hector   27 mar 12 18:54 SRR18335438.fasta -> SRR18335438/
    scaffolds.fasta
drwxrwxr-x 11 hector hector 4,0K mar 11 13:54 SRR22388518
lrwxrwxrwx  1 hector hector   27 mar 12 18:54 SRR22388518.fasta -> SRR22388518/
    scaffolds.fasta
drwxrwxr-x 11 hector hector 4,0K mar 12 13:43 SRR22388519
lrwxrwxrwx  1 hector hector   27 mar 12 18:54 SRR22388519.fasta -> SRR22388519/
    scaffolds.fasta
```

Finalmente, con todos los ensamblajes listos, procederemos a analizar su calidad.

5 Control de calidad de ensamblajes

En este paso se calcularán sobre cada ensamblaje, varias métricas que pueden ser usadas como indicadores de su calidad.

5.1 Software requerido

Software	Versión	Descripción	Ref.
Quast	5.2.0	Herramienta para evaluar la calidad de ensamblajes de genomas (pequeños) y metagenomas, mediante el cálculo de diferentes métricas.	Gurevich et al. (2013); Sitio Web; repositorio GitHub

5.2 Determinación de calidad

EL cálculo de las métricas se realiza usando el software Quast (del inglés ***QU**ality **AS**sessment **T**ool*). Aunque esta herramienta funciona sin un genoma de referencia, la evaluación de calidad será mejor si se provee uno. Este genoma podrá ser el del organismo más cercano o, como en nuestro caso, el del propio organismo(*H. pylori*[1]). Como tenemos acceso a un genoma de referencia, lo usaremos.

[1] *NCBI Datasets Genome page of Helicobacter pylori: https://www.ncbi.nlm.nih.gov/labs/data-hub/genome/GCF_017821535.1/*

5.2.1 Descarga del genoma de referencia

El número de acceso (*accession number*) del genoma de referencia de *H. pylori*, es GCF_017821535.1. Este número es necesario para descargar el archivo del genoma con la herramienta `datasets`:

```
# Entrar al directorio datos del proyecto
cd $HOME/proyectos/ensamblaje/datos

# Descargar el paquete de datos con el genoma
datasets download genome accession GCF_017821535.1 --filename GCF_017821535.1
    _dataset.zip
```

```
Collecting 1  records [==============================================] 100% 1/1
Downloading: GCF_017821535.1_dataset.zip    473kB done
```

Descargado el paquete de datos con el genoma, debemos descomprimirlo:

```
unzip GCF_017821535.1_dataset.zip
```

```
Archive:  GCF_017821535.1_dataset.zip
  inflating: README.md
  inflating: ncbi_dataset/data/assembly_data_report.jsonl
  inflating: ncbi_dataset/data/GCF_017821535.1/GCF_017821535.1_ASM1782153v1_genomic
      .fna
  inflating: ncbi_dataset/data/dataset_catalog.json
```

Al descomprimir el paquete se generaron dos elemento, el archivo `README.md` y el directorio `ncbi_dataset`. El archivo que necesitamos es `ncbi_dataset/data/GCF_017821535.1/GCF_017821535.1_ASM1782153v1_genomic.fna`, así que lo moveremos y renombraremos a la ubicación apropiada:

```
mv ncbi_dataset/data/GCF_017821535.1/GCF_017821535.1_ASM1782153v1_genomic.fna \
  GCF_017821535.1.fasta
```

Ahora podemos eliminar los archivos que no usaremos:

```
rm -fr README.md ncbi_dataset GCF_017821535.1_dataset.zip
```

5.2.2 Ejecución de Quast

```
cd $HOME/proyectos/ensamblaje

quast -o resultados/02_ensamblaje_qc/SRR22388518 \
  -r datos/GCF_017821535.1.fasta \
  -t 4 \
  resultados/01_ensamblaje/SRR22388518.fasta
```

```
/home/hector/mambaforge/envs/ensam/bin/quast -o resultados/02_ensamblaje_qc/
    SRR22388518 -r datos/GCF_017821535.1.fasta -t 4 resultados/01_ensamblaje/
    SRR22388518.fasta

Version: 5.2.0

System information:
  OS: Linux-5.15.0-67-generic-x86_64-with-glibc2.31 (linux_64)
  Python version: 3.10.6
  CPUs number: 8

Started: 2023-03-12 20:15:20

Logging to /home/hector/proyectos/ensamblaje/resultados/02_ensamblaje_qc/
    SRR22388518/quast.log

...

RESULTS:
  Text versions of total report are saved to /home/hector/proyectos/ensamblaje/
      resultados/02_ensamblaje_qc/SRR22388518/report.txt, report.tsv, and report.
      tex
  Text versions of transposed total report are saved to /home/hector/proyectos/
      ensamblaje/resultados/02_ensamblaje_qc/SRR22388518/transposed_report.txt,
      transposed_report.tsv, and transposed_report.tex
  HTML version (interactive tables and plots) is saved to /home/hector/proyectos/
      ensamblaje/resultados/02_ensamblaje_qc/SRR22388518/report.html
  PDF version (tables and plots) is saved to /home/hector/proyectos/ensamblaje/
      resultados/02_ensamblaje_qc/SRR22388518/report.pdf
  Icarus (contig browser) is saved to /home/hector/proyectos/ensamblaje/resultados
      /02_ensamblaje_qc/SRR22388518/icarus.html
  Log is saved to /home/hector/proyectos/ensamblaje/resultados/02_ensamblaje_qc/
      SRR22388518/quast.log
```

```
Finished: 2023-03-12 20:15:24
Elapsed time: 0:00:04.507330
NOTICEs: 3; WARNINGs: 0; non-fatal ERRORs: 0

Thank you for using QUAST!
```

Quast genera un reporte en diferentes formatos: texto (.txt y .tsv), LaTeX (.tex), html (.html) y pdf (.pdf).

Bibliografía

Chen, Shifu, Yanqing Zhou, Yaru Chen, y Jia Gu. 2018. «fastp: an ultra-fast all-in-one FASTQ preprocessor». *Bioinformatics* 34 (17): i884-90. https://doi.org/10.1093/bioinformatics/bty560.

Cock, Peter J. A., Christopher J. Fields, Naohisa Goto, Michael L. Heuer, y Peter M. Rice. 2010. «The Sanger FASTQ file format for sequences with quality scores, and the Solexa/Illumina FASTQ variants». *Nucleic Acids Research* 38 (6): 1767-71. https://doi.org/10.1093/nar/gkp1137.

Compeau, Phillip E. C., Pavel A. Pevzner, y Glenn Tesler. 2011. «Why are de Bruijn graphs useful for genome assembly?» *Nature biotechnology* 29 (11): 987-91. https://doi.org/10.1038/nbt.2023.

Ewels, Philip, Måns Magnusson, Sverker Lundin, y Max Käller. 2016. «MultiQC: summarize analysis results for multiple tools and samples in a single report». *Bioinformatics* 32 (19): 3047-48. https://doi.org/10.1093/bioinformatics/btw354.

Gurevich, Alexey, Vladislav Saveliev, Nikolay Vyahhi, y Glenn Tesler. 2013. «QUAST: quality assessment tool for genome assemblies». *Bioinformatics* 29 (8): 1072-75. https://doi.org/10.1093/bioinformatics/btt086.

Katz, Kenneth, Oleg Shutov, Richard Lapoint, Michael Kimelman, J Rodney Brister, y Christopher O'Sullivan. 2022. «The Sequence Read Archive: a decade more of explosive growth». *Nucleic Acids Research* 50 (D1): D387-90. https://doi.org/10.1093/nar/gkab1053.

Prjibelski, Andrey, Dmitry Antipov, Dmitry Meleshko, Alla Lapidus, y Anton Korobeynikov. 2020. «Using SPAdes De Novo Assembler». *Current Protocols in Bioinformatics* 70 (1): e102. https://doi.org/10.1002/cpbi.102.

Wick, Ryan R., Mark B. Schultz, Justin Zobel, y Kathryn E. Holt. 2015. «Bandage: interactive visualization of de novo genome assemblies». *Bioinformatics* 31 (20): 3350-52. https://doi.org/10.1093/bioinformatics/btv383.

A FastQC help

> **Nota**
>
> Esta es una copia de la ayuda de FastQC (en inglés) disponible en https://www.bioinformatics.babraham.ac.uk/projects/fastqc/Help/

A.1 Introduction

A.1.1 What is FastQC

Modern high throughput sequencers can generate hundreds of millions of sequences in a single run. Before analysing this sequence to draw biological conclusions you should always perform some simple quality control checks to ensure that the raw data looks good and there are no problems or biases in your data which may affect how you can usefully use it.

Most sequencers will generate a QC report as part of their analysis pipeline, but this is usually only focused on identifying problems which were generated by the sequencer itself. FastQC aims to provide a QC report which can spot problems which originate either in the sequencer or in the starting library material.

FastQC can be run in one of two modes. It can either run as a stand alone interactive application for the immediate analysis of small numbers of FastQ files, or it can be run in a non-interactive mode where it would be suitable for integrating into a larger analysis pipeline for the systematic processing of large numbers of files.

A.2 Basic Operations

A.2.1 Opening a Sequence file

To open one or more Sequence files interactively simply run the program and select File > Open. You can then select the files you want to analyse.

Newly opened files will immediately appear in the set of tabs at the top of the screen. Because of the size of these files it can take a couple of minutes to open them. FastQC operates a queueing system where only one file is opened at a time, and new files will wait until existing files have been processed.

FastQC supports files in the following formats

- FastQ (all quality encoding variants)
- Casava FastQ files[1]
- Colorspace FastQ
- GZip compressed FastQ
- SAM
- BAM
- SAM/BAM Mapped only (normally used for colorspace data)

By default FastQC will try to guess the file format from the name of the input file. Anything ending in .sam or .bam will be opened as a SAM/BAM file (using all sequences, mapped and unmapped) , and everything else will be treated as FastQ format. If you want to override this detection and specify the file format manually then you can use the drop down file filter in the file chooser to select the type of file you're going to load. You need to use the drop down selector to make the program use the Mapped BAM or Casava file modes as these won't be selected automatically.

A.2.2 Evaluating Results

The analysis in FastQC is performed by a series of analysis modules. The left hand side of the main interactive display or the top of the HTML report show a summary of the modules which were run, and a quick evaluation of whether the results of the module seem entirely normal (green tick), slightly abnormal (orange triangle) or very unusual (red cross).

It is important to stress that although the analysis results appear to give a pass/fail result, these evaluations must be taken in the context of what you expect from your library. A 'normal' sample as far as FastQC is concerned is random and diverse. Some experiments may be expected to produce libraries which are biased in particular ways. You should treat the summary evaluations therefore as pointers to where you should concentrate your attention and understand why your library may not look random and diverse.

Specific guidance on how to interpret the output of each module can be found in the modules section of the help.

[1] Casava fastq format is the same as regular fastq except that the data is usually split across multiple files for a single sample. In this mode the program will merge the files in a sample group and present a single report for each sample. Also Casava fastq files contain poor quality sequences which have been flagged to be remove. In Casava mode the program will exclude these flagged sequences from the report.

A.2.3 Saving a Report

In addition to providing an interactive report FastQC also has the option to create an HTML version of this report for a more permanent record. This HTML report can also be generated directly by running FastQC in non-interactive mode.

To create a report simply select File > Save Report from the main menu. By default a report will be created using the name of the fastq file with _fastqc.html appended to the end. The report will be created for whichever file tab was active when the menu option was selected.

The HTML file which is saved is a self-contained document with all of the graphs embedded into it, so you can distribute this single file. Alongside the HTML file is a zip file (with the same name as the HTML file, but with .zip added to the end). This file contains the graphs from the report as separate files but also contains data files which are designed to be easily parsed to allow for a more detailed and automated evauation of the raw data on which the QC report is built.

A.3 Analysis Modules

A.3.1 Basic Statistics

A.3.1.1 Summary

The Basic Statistics module generates some simple composition statistics for the file analysed.

- Filename: The original filename of the file which was analysed
- File type: Says whether the file appeared to contain actual base calls or colorspace data which had to be converted to base calls
- Encoding: Says which ASCII encoding of quality values was found in this file.
- Total Sequences: A count of the total number of sequences processed. There are two values reported, actual and estimated. At the moment these will always be the same. In the future it may be possible to analyse just a subset of sequences and estimate the total number, to speed up the analysis, but since we have found that problematic sequences are not evenly distributed through a file we have disabled this for now.
- Filtered Sequences: If running in Casava mode sequences flagged to be filtered will be removed from all analyses. The number of such sequences removed will be reported here. The total sequences count above will not include these filtered sequences and will the number of sequences actually used for the rest of the analysis.
- Sequence Length: Provides the length of the shortest and longest sequence in the set. If all sequences are the same length only one value is reported.
- %GC: The overall %GC of all bases in all sequences

A.3.1.2 Warning

Basic Statistics never raises a warning.

A.3.1.3 Failure

Basic Statistics never raises an error.

A.3.1.4 Common reasons for warnings

This module never raises warnings or errors

A.3.2 Adapter Content

A.3.2.1 Summary

The Kmer Content module will do a generic analysis of all of the Kmers in your library to find those which do not have even coverage through the length of your reads. This can find a number of different sources of bias in the library which can include the presence of read-through adapter sequences building up on the end of your sequences.

You can however find that the presence of any overrepresented sequences in your library (such as adapter dimers) will cause the Kmer plot to be dominated by the Kmers these sequences contain, and that it's not always easy to see if there are other biases present in which you might be interested.

One obvious class of sequences which you might want to analyse are adapter sequences. It is useful to know if your library contains a significant amount of adapter in order to be able to assess whether you need to adapter trim or not. Although the Kmer analysis can theoretically spot this kind of contamination it isn't always clear. This module therefore does a specific search for a set of separately defined Kmers and will give you a view of the total proportion of your library which contain these Kmers. A results trace will always be generated for all of the sequences present in the adapter config file so you can see the adapter content of your library, even if it's low.

The plot itself shows a cumulative percentage count of the proportion of your library which has seen each of the adapter sequences at each position. Once a sequence has been seen in a read it is counted as being present right through to the end of the read so the percentages you see will only increase as the read length goes on.

In addition to classic adapter sequences the default configuration also includes polyA and polyG as sequences to search for. PolyA can be useful to include when looking at RNA-Seq

libraries. PolyG is present as a technical artefact in 2-colour illumina libraries where it is produced when the signal from the cluster disappears. Both of these sequences are generally trimmed from the 3' end of sequences, and are therefore removed in a similar way to adapters, hence their inclusion in the default configuration. These sequences can be removed by editing the adapter_list.txt file in the Configuration directory.

A.3.2.2 Warning

This module will issue a warning if any sequence is present in more than 5% of all reads.

A.3.2.3 Failure

This module will issue a warning if any sequence is present in more than 10% of all reads.

A.3.2.4 Common reasons for warnings

Any library where a reasonable proportion of the insert sizes are shorter than the read length will trigger this module. This doesn't indicate a problem as such - just that the sequences will need to be adapter trimmed before proceeding with any downstream analysis.

A.3.3 Kmer Content

A.3.3.1 Summary

The analysis of overrepresented sequences will spot an increase in any exactly duplicated sequences, but there are a different subset of problems where it will not work.

- If you have very long sequences with poor sequence quality then random sequencing errors will dramatically reduce the counts for exactly duplicated sequences.
- If you have a partial sequence which is appearing at a variety of places within your sequence then this won't be seen either by the per base content plot or the duplicate sequence analysis.

The Kmer module starts from the assumption that any small fragment of sequence should not have a positional bias in its apearance within a diverse library. There may be biological reasons why certain Kmers are enriched or depleted overall, but these biases should affect all positions within a sequence equally. This module therefore measures the number of each 7-mer at each position in your library and then uses a binomial test to look for significant deviations from an even coverage at all positions. Any Kmers with positionally biased enrichment are reported. The top 6 most biased Kmer are additionally plotted to show their distribution.

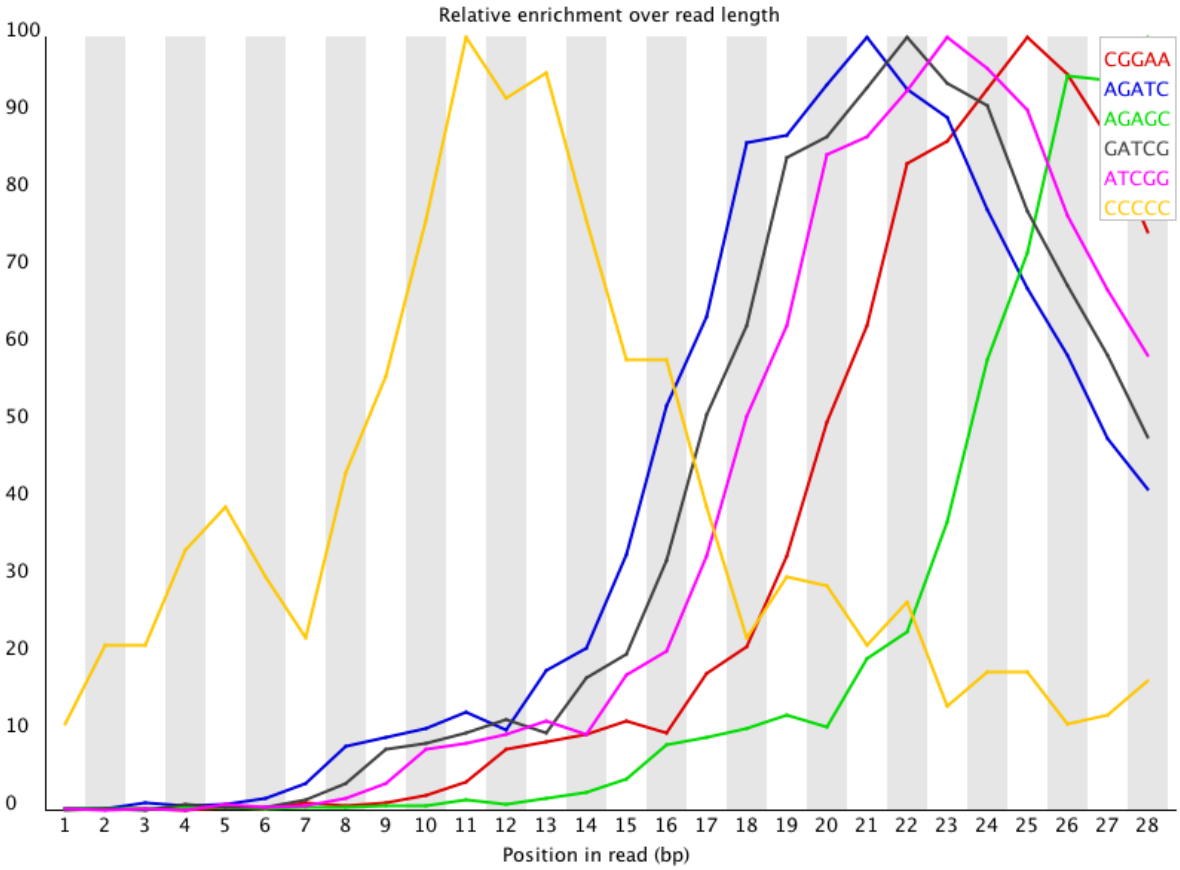

Figura A.1: Kmer profiles

To allow this module to run in a reasonable time only 2% of the whole library is analysed and the results are extrapolated to the rest of the library. Sequences longer than 500bp are truncated to 500bp for this analysis.

A.3.3.2 Warning

This module will issue a warning if any k-mer is imbalanced with a binomial p-value <0.01.

A.3.3.3 Failure

This module will issue a warning if any k-mer is imbalanced with a binomial p-value < 10^-5.

A.3.3.4 Common reasons for warnings

Any individually overrepresented sequences, even if not present at a high enough threshold to trigger the overrepresented sequences module will cause the Kmers from those sequences to be highly enriched in this module. These will normally appear as sharp spikes of enrichemnt at a single point in the sequence, rather than a progressive or broad enrichment.

Libraries which derive from random priming will nearly always show Kmer bias at the start of the library due to an incomplete sampling of the possible random primers.

A.3.4 Per Tile Sequence Quality

A.3.4.1 Summary

This graph will only appear in your analysis results if you're using an Illumina library which retains its original sequence identifiers. Encoded in these is the flowcell tile from which each read came. The graph allows you to look at the quality scores from each tile across all of your bases to see if there was a loss in quality associated with only one part of the flowcell.

The plot shows the deviation from the average quality for each tile. The colours are on a cold to hot scale, with cold colours being positions where the quality was at or above the average for that base in the run, and hotter colours indicate that a tile had worse qualities than other tiles for that base. In the example below you can see that certain tiles show consistently poor quality. A good plot should be blue all over.

Reasons for seeing warnings or errors on this plot could be transient problems such as bubbles going through the flowcell, or they could be more permanent problems such as smudges on the flowcell or debris inside the flowcell lane.

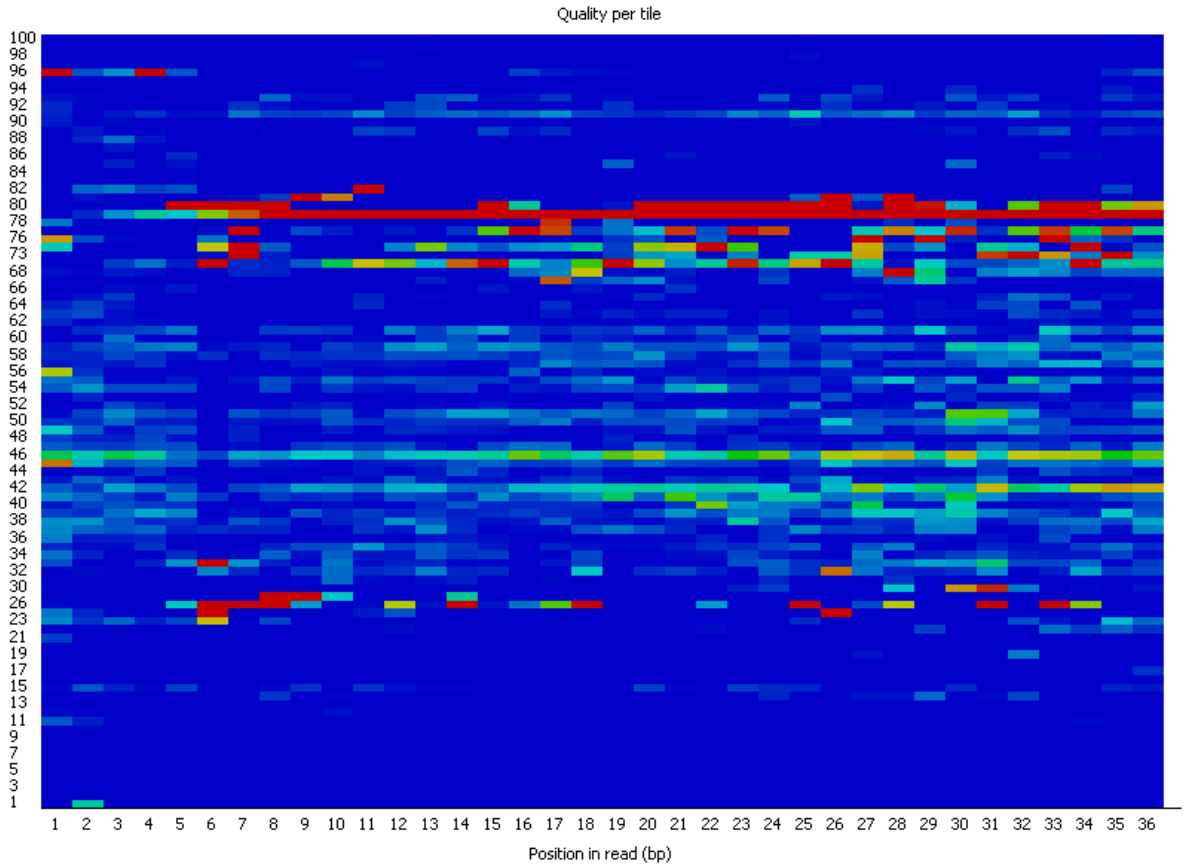

Figura A.2: Kmer profiles

A.3.4.2 Warning

This module will issue a warning if any tile shows a mean Phred score more than 2 less than the mean for that base across all tiles.

A.3.4.3 Failure

This module will raise and error if any tile shows a mean Phred score more than 5 less than the mean for that base across all tiles.

A.3.4.4 Common reasons for warnings

Whilst warnings in this module can be triggered by individual specific events we have also observed that greater variation in the phred scores attributed to tiles can also appear when a flowcell is generally overloaded. In this case events appear all over the flowcell rather than being confined to a specific area or range of cycles. We would generally ignore errors which mildly affected a small number of tiles for only 1 or 2 cycles, but would pursue larger effects which showed high deviation in scores, or which persisted for several cycles.

A.3.5 Per Base Sequence Quality

A.3.5.1 Summary

This view shows an overview of the range of quality values across all bases at each position in the FastQ file.

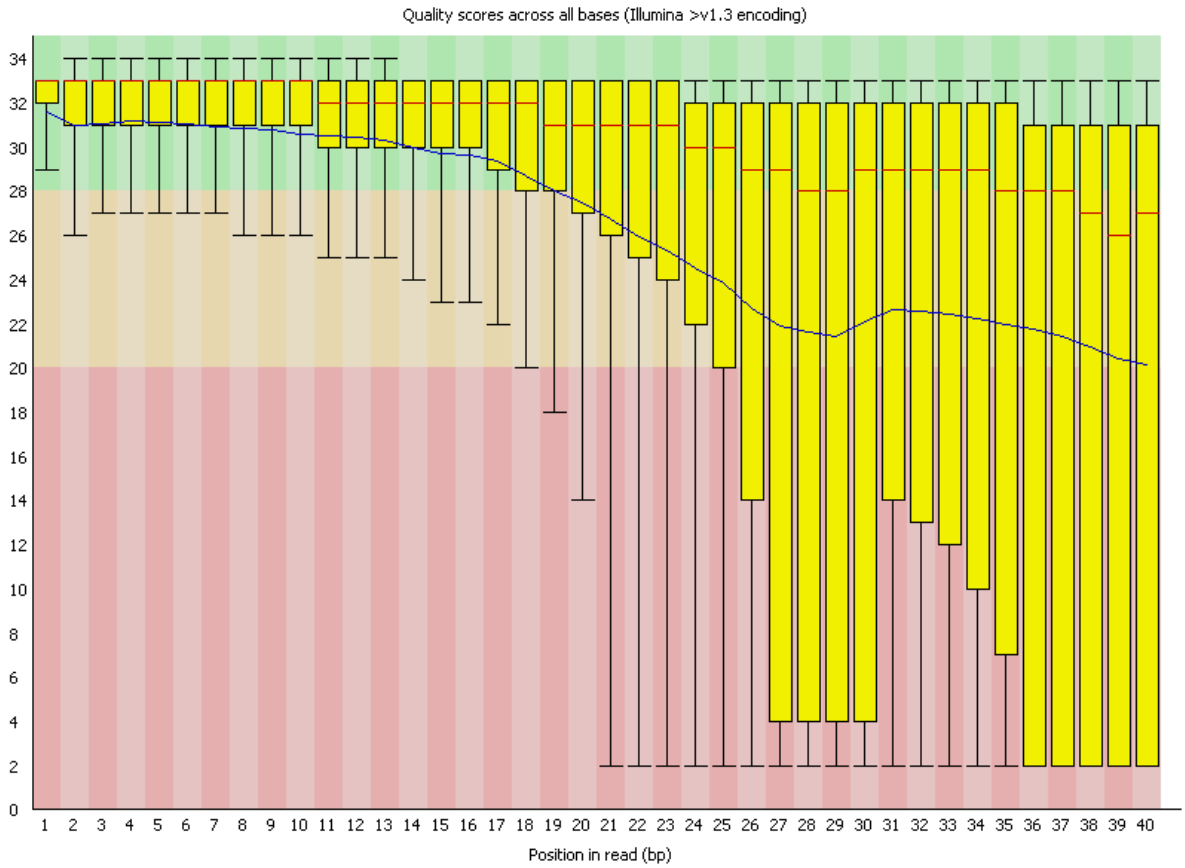

For each position a BoxWhisker type plot is drawn. The elements of the plot are as follows:

- The central red line is the median value
- The yellow box represents the inter-quartile range (25-75%)
- The upper and lower whiskers represent the 10% and 90% points
- The blue line represents the mean quality

The y-axis on the graph shows the quality scores. The higher the score the better the base call. The background of the graph divides the y axis into very good quality calls (green), calls of reasonable quality (orange), and calls of poor quality (red). The quality of calls on most platforms will degrade as the run progresses, so it is common to see base calls falling into the orange area towards the end of a read.

It should be mentioned that there are number of different ways to encode a quality score in a FastQ file. FastQC attempts to automatically determine which encoding method was used, but in some very limited datasets it is possible that it will guess this incorrectly (ironically only when your data is universally very good!). The title of the graph will describe the encoding FastQC thinks your file used.

Results from this module will not be displayed if your input is a BAM/SAM file in which quality scores have not been recorded.

A.3.5.2 Warning

A warning will be issued if the lower quartile for any base is less than 10, or if the median for any base is less than 25.

A.3.5.3 Failure

This module will raise a failure if the lower quartile for any base is less than 5 or if the median for any base is less than 20.

A.3.5.4 Common reasons for warnings

The most common reason for warnings and failures in this module is a general degradation of quality over the duration of long runs. In general sequencing chemistry degrades with increasing read length and for long runs you may find that the general quality of the run falls to a level where a warning or error is triggered.

If the quality of the library falls to a low level then the most common remedy is to perform quality trimming where reads are truncated based on their average quality. For most libraries where this type of degradation has occurred you will often be simultaneously running into the issue of adapter read-through so a combined adapter and quality trimming step is often employed.

Another possibility is that a warn / error is triggered because of a short loss of quality earlier in the run, which then recovers to produce later good quality sequence. This can happen if there is a transient problem with the run (bubbles passing through a flowcell for example). You can normally see this type of error by looking at the per-tile quality plot (if available for your platform). In these cases trimming is not advisable as it will remove later good sequence, but you might want to consider masking bases during subsequent mapping or assembly.

If your library has reads of varying length then you can find a warning or error is triggered from this module because of very low coverage for a given base range. Before committing to any action, check how many sequences were responsible for triggering an error by looking at the sequence length distribution module results.

A.3.6 Per Sequence Quality Scores

A.3.6.1 Summary

The per sequence quality score report allows you to see if a subset of your sequences have universally low quality values. It is often the case that a subset of sequences will have universally poor quality, often because they are poorly imaged (on the edge of the field of view etc), however these should represent only a small percentage of the total sequences.

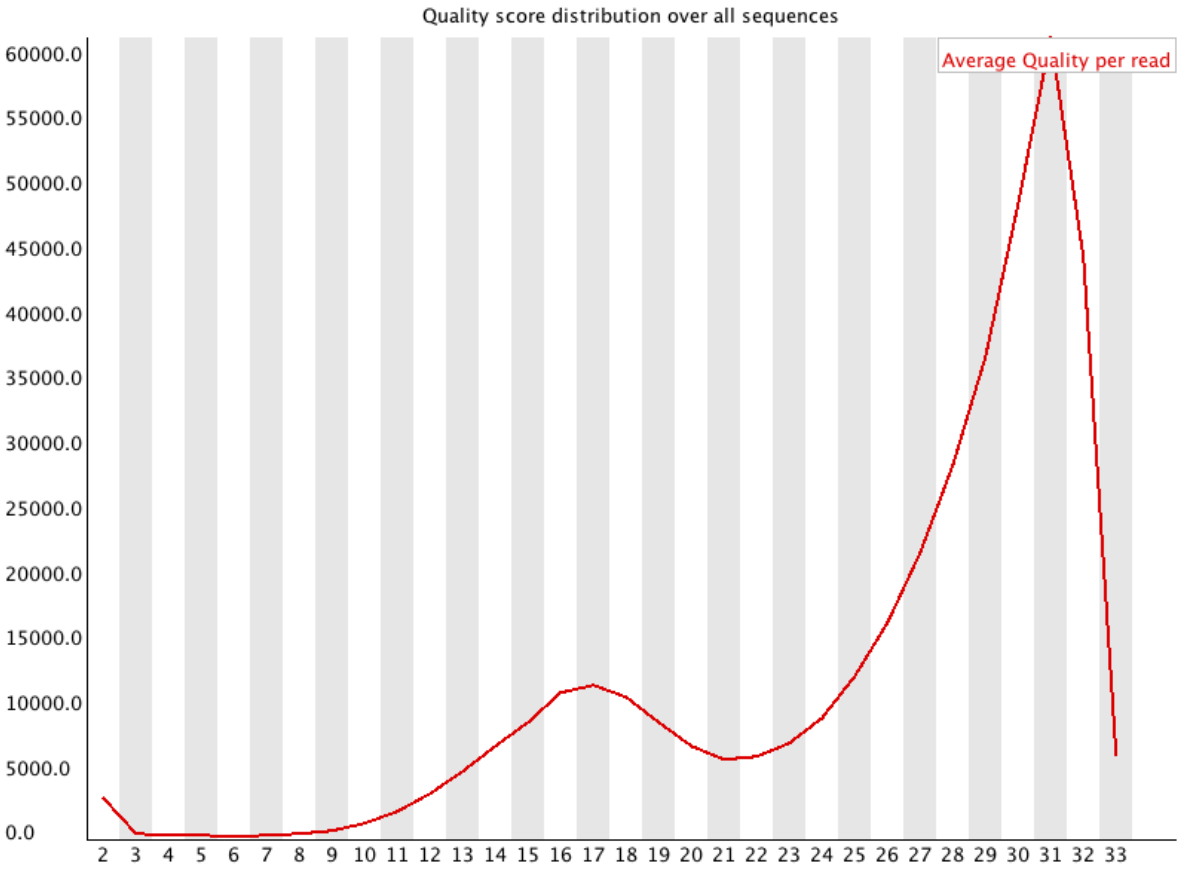

If a significant proportion of the sequences in a run have overall low quality then this could indicate some kind of systematic problem - possibly with just part of the run (for example one end of a flowcell).

Results from this module will not be displayed if your input is a BAM/SAM file in which quality scores have not been recorded.

A.3.6.2 Warning

A warning is raised if the most frequently observed mean quality is below 27 - this equates to a 0.2% error rate.

A.3.6.3 Failure

An error is raised if the most frequently observed mean quality is below 20 - this equates to a 1% error rate.

A.3.6.4 Common reasons for warnings

This module is generally fairly robust and errors here usually indicate a general loss of quality within a run. For long runs this may be alleviated through quality trimming. If a bi-modal, or complex distribution is seen then the results should be evaluated in concert with the per-tile qualities (if available) since this might indicate the reason for the loss in quality of a subset of sequences.

A.3.7 Per Base Sequence Content

A.3.7.1 Summary

Per Base Sequence Content plots out the proportion of each base position in a file for which each of the four normal DNA bases has been called.

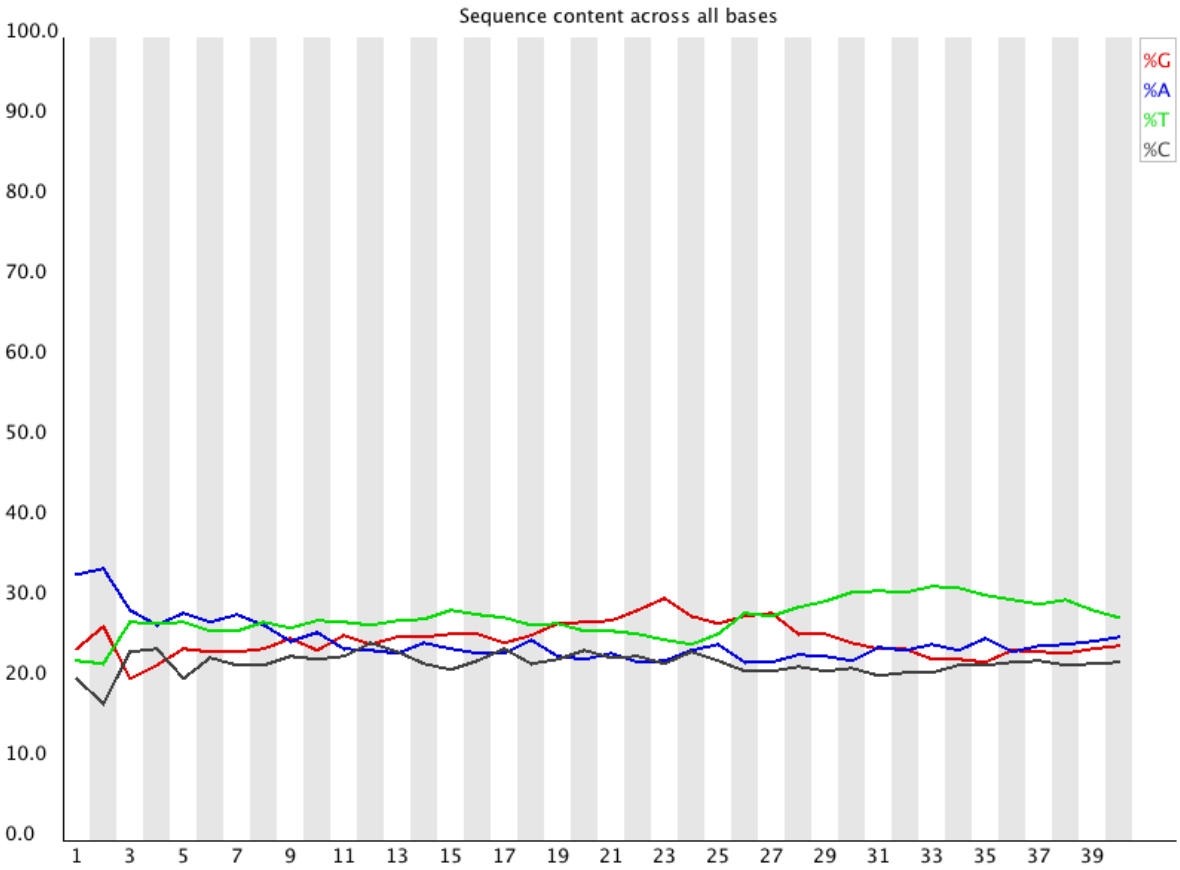

In a random library you would expect that there would be little to no difference between the different bases of a sequence run, so the lines in this plot should run parallel with each other. The relative amount of each base should reflect the overall amount of these bases in your genome, but in any case they should not be hugely imbalanced from each other.

It's worth noting that some types of library will always produce biased sequence composition, normally at the start of the read. Libraries produced by priming using random hexamers (including nearly all RNA-Seq libraries) and those which were fragmented using transposases inherit an intrinsic bias in the positions at which reads start. This bias does not concern an absolute sequence, but instead provides enrichement of a number of different K-mers at the 5' end of the reads. Whilst this is a true technical bias, it isn't something which can be corrected by trimming and in most cases doesn't seem to adversely affect the downstream analysis. It will however produce a warning or error in this module.

A.3.7.2 Warning

This module issues a warning if the difference between A and T, or G and C is greater than 10% in any position.

A.3.7.3 Failure

This module will fail if the difference between A and T, or G and C is greater than 20% in any position.

A.3.7.4 Common reasons for warnings

There are a number of common scenarios which would ellicit a warning or error from this module.

Overrepresented sequences: If there is any evidence of overrepresented sequences such as adapter dimers or rRNA in a sample then these sequences may bias the overall composition and their sequence will emerge from this plot.

Biased fragmentation: Any library which is generated based on the ligation of random hexamers or through tagmentation should theoretically have good diversity through the sequence, but experience has shown that these libraries always have a selection bias in around the first 12bp of each run. This is due to a biased selection of random primers, but doesn't represent any individually biased sequences. Nearly all RNA-Seq libraries will fail this module because of this bias, but this is not a problem which can be fixed by processing, and it doesn't seem to adversely affect the ablity to measure expression.

Biased composition libraries: Some libraries are inherently biased in their sequence composition. The most obvious example would be a library which has been treated with sodium bisulphite which will then have converted most of the cytosines to thymines, meaning that the base composition will be almost devoid of cytosines and will thus trigger an error, despite this being entirely normal for that type of library

If you are analysing a library which has been aggressivley adapter trimmed then you will naturally introduce a composition bias at the end of the reads as sequences which happen to match short stretches of adapter are removed, leaving only sequences which do not match. Sudden deviations in composition at the end of libraries which have undergone aggressive trimming are therefore likely to be spurious.

A.3.8 Per Sequence GC Content

A.3.8.1 Summary

This module measures the GC content across the whole length of each sequence in a file and compares it to a modelled normal distribution of GC content.

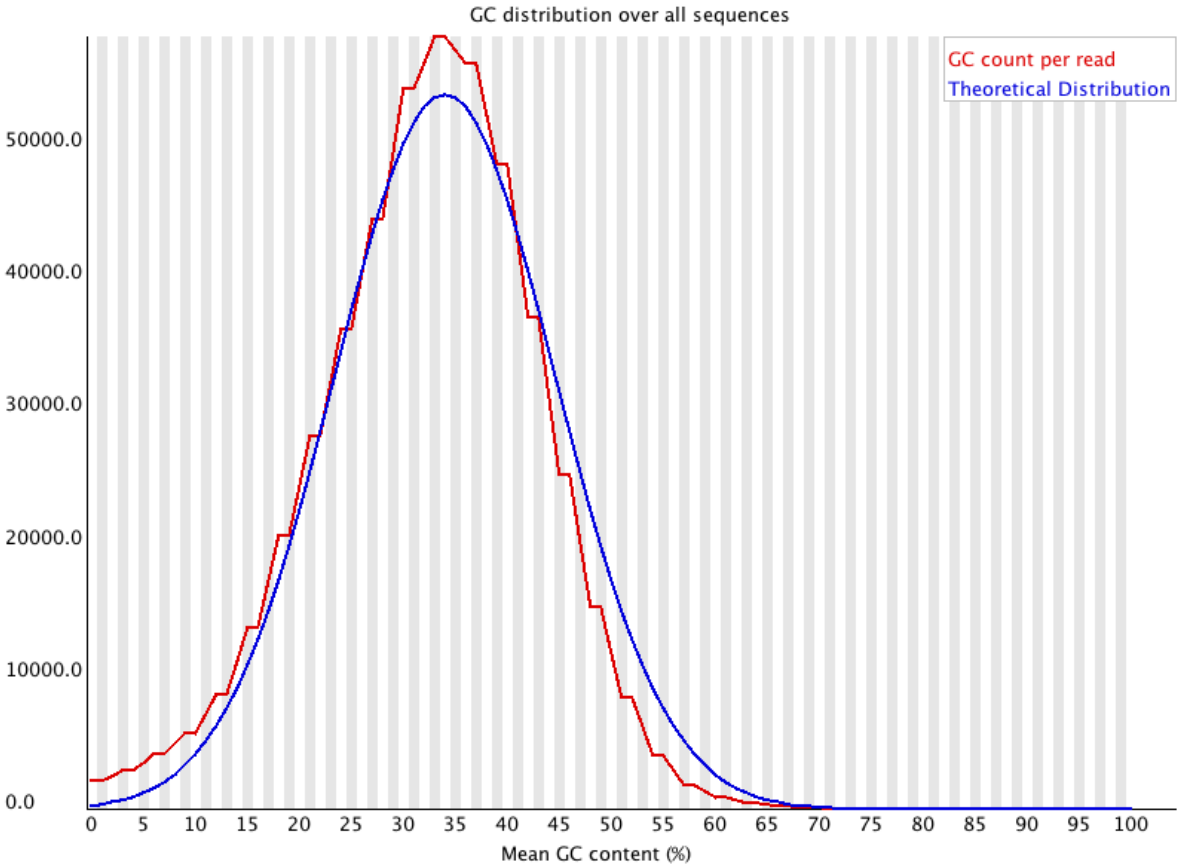

In a normal random library you would expect to see a roughly normal distribution of GC content where the central peak corresponds to the overall GC content of the underlying genome. Since we don't know the the GC content of the genome the modal GC content is calculated from the observed data and used to build a reference distribution.

An unusually shaped distribution could indicate a contaminated library or some other kinds of biased subset. A normal distribution which is shifted indicates some systematic bias which is independent of base position. If there is a systematic bias which creates a shifted normal distribution then this won't be flagged as an error by the module since it doesn't know what your genome's GC content should be.

A.3.8.2 Warning

A warning is raised if the sum of the deviations from the normal distribution represents more than 15% of the reads.

A.3.8.3 Failure

This module will indicate a failure if the sum of the deviations from the normal distribution represents more than 30% of the reads.

A.3.8.4 Common reasons for warnings

Warnings in this module usually indicate a problem with the library. Sharp peaks on an otherwise smooth distribution are normally the result of a specific contaminant (adapter dimers for example), which may well be picked up by the overrepresented sequences module. Broader peaks may represent contamination with a different species.

A.3.9 Per Base N Content

A.3.9.1 Summary

If a sequencer is unable to make a base call with sufficient confidence then it will normally substitute an N rather than a conventional base] call

This module plots out the percentage of base calls at each position for which an N was called.

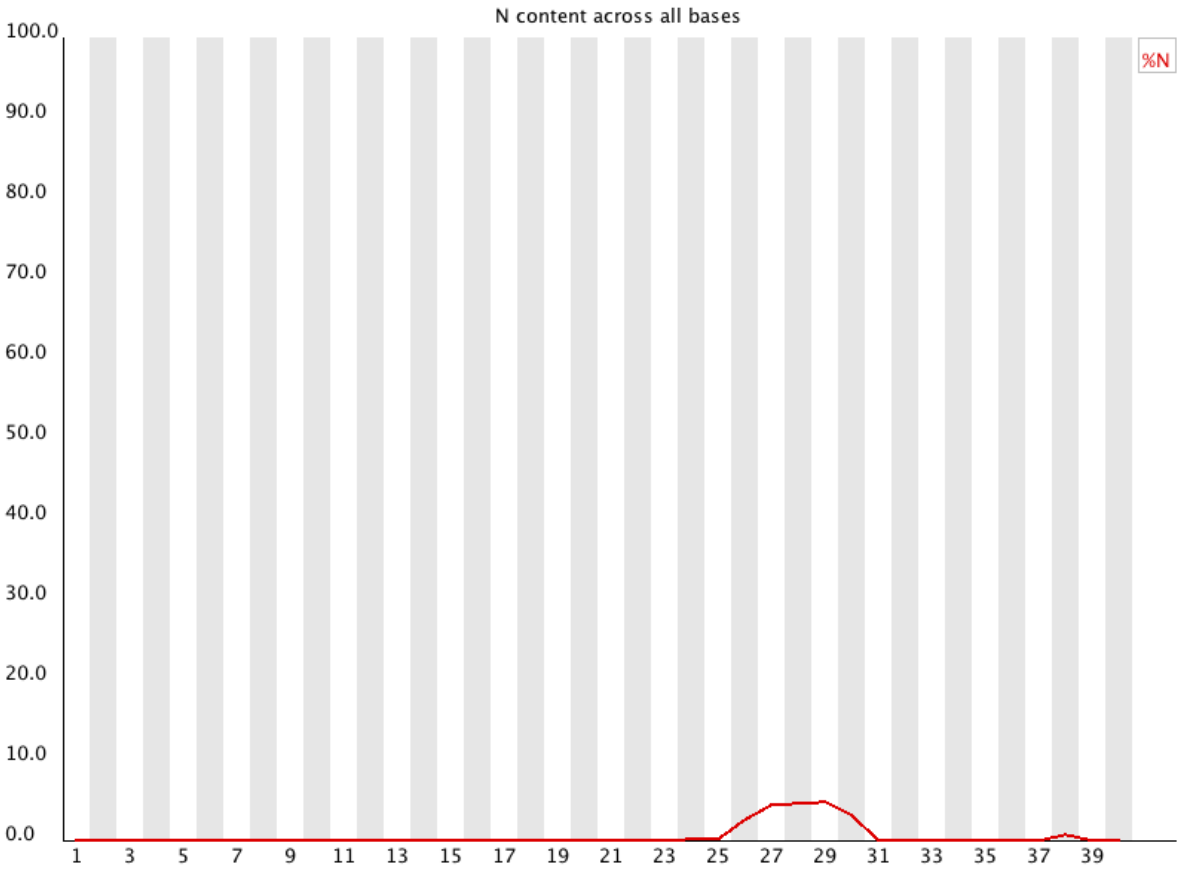

It's not unusual to see a very low proportion of Ns appearing in a sequence, especially nearer the end of a sequence. However, if this proportion rises above a few percent it suggests that the analysis pipeline was unable to interpret the data well enough to make valid base calls.

A.3.9.2 Warning

This module raises a warning if any position shows an N content of >5%.

A.3.9.3 Failure

This module will raise an error if any position shows an N content of >20%.

A.3.9.4 Common reasons for warnings

The most common reason for the inclusion of significant proportions of Ns is a general loss of quality, so the results of this module should be evaluated in concert with those of the various quality modules. You should check the coverage of a specific bin, since it's possible that the last bin in this analysis could contain very few sequences, and an error could be prematurely triggered in this case.

Another common scenario is the incidence of a high proportions of N at a small number of positions early in the library, against a background of generally good quality. Such deviations can occur when you have very biased sequence composition in the library to the point that base callers can become confused and make poor calls. This type of problem will be apparent when looking at the per-base sequence content results.

A.3.10 Sequence Length Distribution

A.3.10.1 Summary

Some high throughput sequencers generate sequence fragments of uniform length, but others can contain reads of wildly varying lengths. Even within uniform length libraries some pipelines will trim sequences to remove poor quality base calls from the end.

This module generates a graph showing the distribution of fragment sizes in the file which was analysed.

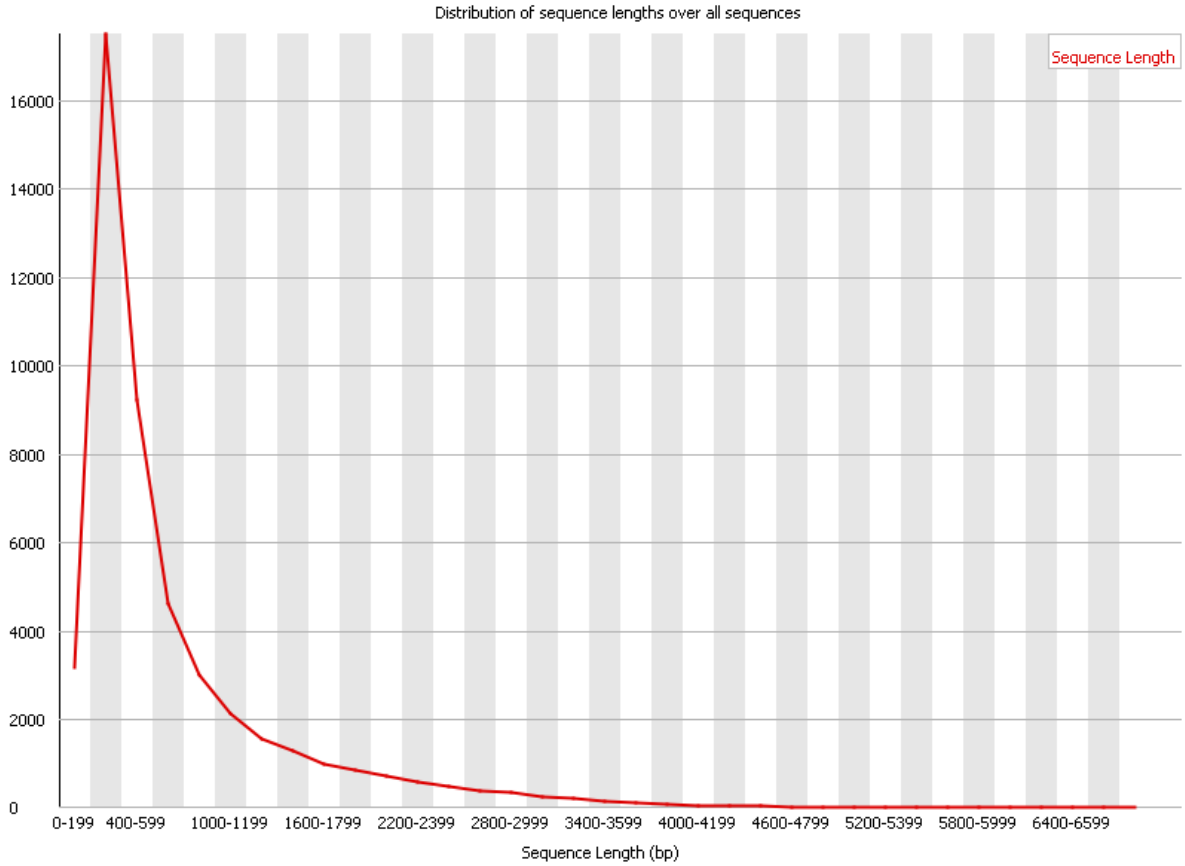

In many cases this will produce a simple graph showing a peak only at one size, but for variable length FastQ files this will show the relative amounts of each different size of sequence fragment.

A.3.10.2 Warning

This module will raise a warning if all sequences are not the same length.

A.3.10.3 Failure

This module will raise an error if any of the sequences have zero length.

A.3.10.4 Common reasons for warnings

For some sequencing platforms it is entirely normal to have different read lengths so warnings here can be ignored.

A.3.11 Duplicate Sequences

A.3.11.1 Summary

In a diverse library most sequences will occur only once in the final set. A slightly elevated level of duplication may indicate a very high level of coverage of the target sequence, but a high level of duplication is more likely to indicate some kind of enrichment bias (eg PCR over amplification).

This module counts the degree of duplication for every sequence in a library and creates a plot showing the relative number of sequences with different degrees of duplication.

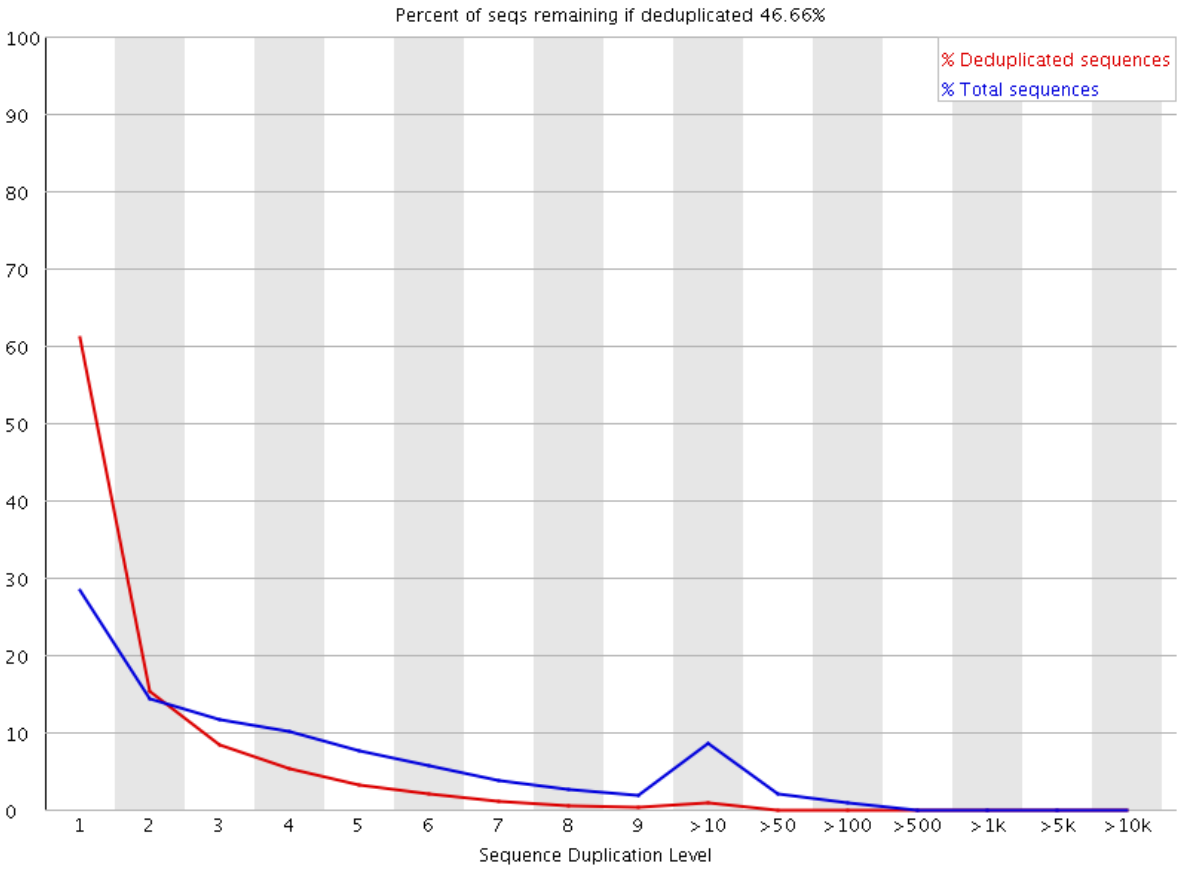

To cut down on the memory requirements for this module only sequences which first appear in the first 100,000 sequences in each file are analysed, and these are then tracked through the entire dataset. This should be enough to get a good impression for the duplication levels in the whole file. Each sequence is tracked to the end of the file to give a representative count of the overall duplication level. To cut down on the amount of information in the final plot any sequences with more than 10 duplicates are placed into grouped bins to give a clear impression of the overall duplication level without having to show each individual duplication value.

Because the duplication detection requires an exact sequence match over the whole length of the sequence, any reads over 50bp in length are truncated to 50bp for the purposes of this analysis. Even so, longer reads are more likely to contain sequencing errors which will artificially increase the observed diversity and will tend to underrepresent highly duplicated sequences.

The plot shows the proportion of the library which is made up of sequences in each of the different duplication level bins. The x axis is the degree of duplication, and the y axis shows the proportion of the library which is made up of reads with that level of duplication.

In a properly diverse library most sequences should fall into the far left of the plot . A general level of enrichment, indicating broad oversequencing in the library will tend to flatten the line, lowering the low end and generally raising other categories. More specific enrichments of subsets, or the presence of low complexity contaminants will tend to produce spikes towards the right of the plot.

The module also calculates an expected overall loss of sequence were the library to be deduplicated. This headline figure is shown at the top of the plot and gives a reasonable impression of the potential overall level of loss.

A.3.11.2 Warning

This module will issue a warning if non-unique sequences make up more than 30% of the total.

A.3.11.3 Failure

This module will issue a error if non-unique sequences make up more than 50% of the total.

A.3.11.4 Common reasons for warnings

The underlying assumption of this module is of a diverse unenriched library. Any deviation from this assumption will naturally generate duplicates and can lead to warnings or errors from this module.

In general there are two potential types of duplicate in a library, technical duplicates arising from PCR artefacts, or biological duplicates which are natural collisions where different copies of exactly the same sequence are randomly selected. From a sequence level there is no way to distinguish between these two types and both will be reported as duplicates here.

A warning or error in this module is simply a statement that you have exhausted the diversity in at least part of your library and are re-sequencing the same sequences. In a supposedly diverse library this would suggest that the diversity has been partially or completely exhausted and that you are therefore wasting sequencing capacity. However in some library types you will naturally tend to over-sequence parts of the library and therefore generate duplication and will therefore expect to see warnings or error from this module.

In RNA-Seq libraries sequences from different transcripts will be present at wildly different levels in the starting population. In order to be able to observe lowly expressed transcripts it is therefore common to greatly over-sequence high expressed transcripts, and this will potentially create large set of duplicates. This will result in high overall duplication in this test, and will often produce peaks in the higher duplication bins. This duplication will come from physically connected regions, and an examination of the distribution of duplicates in a specific genomic region will allow the distinction between over-sequencing and general technical duplication, but these distinctions are not possible from raw fastq files. A similar situation can arise in highly enriched ChIP-Seq libraries although the duplication there is less pronounced. Finally, if you have a library where the sequence start points are constrained (a library constructed around restriction sites for example, or an unfragmented small RNA library) then the constrained start sites will generate huge dupliction levels which should not be treated as a problem, nor removed by deduplication. In these types of library you should consider using a system such as random barcoding to allow the distinction of technical and biological duplicates.

A.3.12 Overrepresented Sequences

A.3.12.1 Summary

A normal high-throughput library will contain a diverse set of sequences, with each individual sequence making up only a tiny fraction of the whole. Finding that a single sequence is very overrepresented in the set either means that it is highly biologically significant, or indicates that the library is contaminated, or not as diverse as you expected.

This module lists all of the sequences which make up more than 0.1% of the total. To conserve memory only sequences which appear in the first 100,000 sequences are tracked to the end of the file. It is therefore possible that a sequence which is overrepresented but doesn't appear at the start of the file for some reason could be missed by this module.

For each overrepresented sequence the program will look for matches in a database of common contaminants and will report the best hit it finds. Hits must be at least 20bp in length and have no more than 1 mismatch. Finding a hit doesn't necessarily mean that this is the source of the contamination, but may point you in the right direction. It's also worth pointing out that many adapter sequences are very similar to each other so you may get a hit reported which isn't technically correct, but which has very similar sequence to the actual match.

Because the duplication detection requires an exact sequence match over the whole length of the sequence any reads over 50bp in length are truncated to 50bp for the purposes of this analysis. Even so, longer reads are more likely to contain sequencing errors which will artificially increase the observed diversity and will tend to underrepresent highly duplicated sequences.

A.3.12.2 Warning

This module will issue a warning if any sequence is found to represent more than 0.1% of the total.

A.3.12.3 Failure

This module will issue an error if any sequence is found to represent more than 1% of the total.

A.3.12.4 Common reasons for warnings

This module will often be triggered when used to analyse small RNA libraries where sequences are not subjected to random fragmentation, and the same sequence may natrually be present in a significant proportion of the library.